

Subject: Stanford CS229 Machine Learning, Lecture 5, Gaussian discriminant analysis, Naive Bayes

Date: from December 14, 2024 to December 16, 2024

Contents

A	Multivariate Gaussian Distribution	6
B	Proof of the solutions of GDA(2-classification case)	7
C	Proof of the decision boundary (10)	9
D	Codes for Multivariate Gaussian Distribution	10

CS229 Machine Learning, Gaussian discriminant analysis, Naive Bayes, 2022, Lecture 5

YouTube: Stanford CS229 Machine Learning, Gaussian discriminant analysis, Naive Bayes, 2022, Lecture 5

Introduction

Generative learning algorithms – Introduction

生成学习算法/生成模型(Generative learning algorithms / Generative model)是一种建模可观察变量 \mathbf{X} 和目标变量 Y 的联合概率分布 $\mathbb{P}(\mathbf{X}, Y)$ 的统计模型，在预测时生成模型可用于“生成”新的观察 \mathbf{x} 的随机实例^{ab}。

生成学习算法主要包括两方面：

1. Gaussian Discriminative analysis (GDA) – 高斯判别分析
2. Naive Bayes – 朴素贝叶斯

在前面的Lecture 中所讲的模型都是Discriminative learning algorithm，因为我们一直在对模型参数化，然后试图寻找最优的参数，例如在Exponential family 模型中

$$y|\mathbf{x}; \theta \sim \text{Exponential family}(\eta), \quad \eta = \theta^T \mathbf{x}$$

其中 θ 是参数。

^a更多介绍可见Wikipedia的Generative model

^b注意这里的生成模型仅仅是一个统计机器学习算法，而非目前很火的生成式人工智能等等

Generative learning algorithms

Model: 在Generative learning algorithms 中，我们希望建模/参数化(Model / Parameterize) 特征 \mathbf{x} 与标签 y 的联合概率分布 $\mathbb{P}(\mathbf{x}, y)$ ，根据条件概率公式，我们有：

$$\mathbb{P}(\mathbf{x}, y) = \mathbb{P}(\mathbf{x}|y)\mathbb{P}(y) \quad (1)$$

其中 y 是所有的标签，一般考虑离散情形，因此如果标签有 N 个类别，那么就需要建模 N 个式(1)。

Learning Time: 在训练时，我们需要学习分布 $\mathbb{P}(\mathbf{x}|y)$ 和 $\mathbb{P}(y)$ ，其中 $\mathbb{P}(y)$ 是label 的先验分布(prior)，一般通过假设/观察确定一种分布，再用参数描述，最后通过学习得到。

Testing Time: 在测试时，我们仍是预测给定特征 \mathbf{x} 的相应标签 y ，本质上是计算条件概率 $\mathbb{P}(y|\mathbf{x})$ 。根据贝叶斯公式(Bayes Rule)和全概率公式(Law of total probability)，有：

$$\mathbb{P}(y|\mathbf{x}) = \frac{\mathbb{P}(\mathbf{x}, y)}{\mathbb{P}(\mathbf{x})} = \frac{\mathbb{P}(\mathbf{x}|y)\mathbb{P}(y)}{\mathbb{P}(\mathbf{x})} = \frac{\mathbb{P}(\mathbf{x}|y)\mathbb{P}(y)}{\sum_{y'} \mathbb{P}(\mathbf{x}|y')\mathbb{P}(y')} \quad (2)$$

根据式(1)，训练阶段已经学习了各个标签的分布 $\mathbb{P}(\mathbf{x}|y)\mathbb{P}(y)$ ，因此只需要根据式(2)计算得到每个标签的 $\mathbb{P}(y|\mathbf{x})$ ，然后选择概率最大的标签作为预测即可。

Gaussian Discriminative analysis(GDA)

Gaussian Discriminative analysis(GDA) – Introduction

在高斯判别分析中，我们考虑高维情形，即 $\mathbf{x} \in \mathbb{R}^d$ ，并且为方便我们规定第一个坐标 $x_0 = 1$ 。

★**Assumption¹**: 假设对于各个标签 y ， $\mathbb{P}(\mathbf{x}|y)$ 满足高维高斯分布，即 $\mathbb{P}(\mathbf{x}|y) \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ 。

Question: 为什么 not 将所有的特征 \mathbf{x} 统一建模成一个高斯分布，而是对于每一个标签分别建立一个高斯分布呢？

Answer: 在实际问题中，不同类别的样本通常具有不同的分布特征。将所有的特征 \mathbf{x} 统一建模为一个高斯分布往往过于简单，无法有效捕捉不同类别之间的差异。

这个假设是高斯判别分析的重要前提，关于高维高斯分布可见附录A

Gaussian Discriminative analysis(GDA) – 2-Classification Case

GDA – 2-Classification Case – Problem and Model

Problem: 考虑一个二分类问题(如图1)，其中训练集为 $\{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$ ，标签 $y \in \{0, 1\}$ 。




Figure 1: Classification

Model: 首先需要假设两个标签所对应的特征的分布都满足高维高斯分布，即^a

$$x|(y=0) \sim \mathcal{N}(\boldsymbol{\mu}_0, \Sigma), \quad \boldsymbol{\mu}_0 \in \mathbb{R}^d, \Sigma \in \mathbb{R}^{d \times d}$$

$$x|(y=1) \sim \mathcal{N}(\boldsymbol{\mu}_1, \Sigma), \quad \boldsymbol{\mu}_1 \in \mathbb{R}^d, \Sigma \in \mathbb{R}^{d \times d}$$

由于是二分类问题，因此标签 y 的先验概率设为参数为 ϕ 的 Bernoulli 分布，即

$$y \sim \text{Bernoulli}(\phi), \quad \mathbb{P}(y=1) = \phi, \quad \mathbb{P}(y=0) = 1 - \phi$$

因此在此模型中参数有四个，为： $\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi$ 。

^a为推导方便设定两个协方差矩阵相同，但当他们不同时也是完全可以推导的，只是复杂一些

GDA – 2-Classification Case – Learn / Fit parameters

Learn / Fit parameters

Before: 为学习模型参数，之前的原则是使得训练集中所有特征-标签对 $\{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$ 在这些参数下的联合概率最大，即最大化似然(maximum likelihood estimation, MLE):

$$\begin{aligned}
 L(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) &= \mathbb{P}((\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(n)}, y^{(n)}); \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) \\
 &\stackrel{i.i.d.}{=} \prod_{i=1}^n \mathbb{P}((\mathbf{x}^{(i)}, y^{(i)}); \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) \\
 &= \prod_{i=1}^n \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) \cdot \mathbb{P}(y^{(i)}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) \\
 &= \prod_{i=1}^n \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma) \cdot \mathbb{P}(y^{(i)}; \phi)
 \end{aligned} \tag{3}$$

其中最后一步化简是因为第一项条件概率与 ϕ 无关，而后一项标签的概率只与 ϕ 有关。

GDA: 在GDA 中，与以往不同的是我们需要最大化条件概率的似然:

$$\begin{aligned}
 L(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) &= \mathbb{P}(y^{(1)}, y^{(2)}, \dots, y^{(n)} | \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) \\
 &\stackrel{i.i.d.}{=} \prod_{i=1}^n \mathbb{P}(y^{(i)} | \mathbf{x}^{(i)}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi)
 \end{aligned} \tag{4}$$

可以看出，在GDA 中我们更关心在观测到 \mathbf{x} 后 y 的概率，而并不对 \mathbf{x} 进行单独建模。

GDA – 2-Classification Case – Solutions

Optimize: 与前面Lecture 中一样，在式(3)中最大化似然函数等价于最大化对数似然:

$$\begin{aligned}
 \arg \max L(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) &= \arg \max \log (L(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi)) \triangleq \arg \max l(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) \\
 &= \arg \max \sum_{i=1}^n \left[\log \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)}) + \log \mathbb{P}(y^{(i)}) \right]
 \end{aligned} \tag{5}$$

此时只需令 $\nabla l(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) = 0$ ，即^a

$$\frac{\partial l}{\partial \phi} = 0, \frac{\partial l}{\partial \boldsymbol{\mu}_0} = 0, \frac{\partial l}{\partial \boldsymbol{\mu}_1} = 0, \frac{\partial l}{\partial \Sigma} = 0 \tag{6}$$

Solutions: 首先为将不同标签对应的特征区分开，先定义两个指标集合:

$$U_0 = \{i : y^{(i)} = 0\}, \quad U_1 = \{i : y^{(i)} = 1\}$$

那么根据式(6)最终可以解出(证明详见附录B):

$$\phi = \frac{|U_1|}{n} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y^{(i)} = 1) \tag{7}$$

$$\mu_0 = \frac{1}{|U_0|} \sum_{i \in U_0} \mathbf{x}^{(i)} = \frac{1}{\sum_{i=1}^n \mathbb{I}(y^{(i)} = 0)} \left(\sum_{i=1}^n \mathbf{x}^{(i)} \cdot \mathbb{I}(y^{(i)} = 0) \right) \quad (8)$$

$$\mu_1 = \frac{1}{|U_1|} \sum_{i \in U_1} \mathbf{x}^{(i)} = \frac{1}{\sum_{i=1}^n \mathbb{I}(y^{(i)} = 1)} \left(\sum_{i=1}^n \mathbf{x}^{(i)} \cdot \mathbb{I}(y^{(i)} = 1) \right)$$

$$\begin{aligned} \Sigma &= \frac{1}{n} \sum_{i=1}^n \left(\mathbf{x}^{(i)} - \mu_{y^{(i)}} \right) \left(\mathbf{x}^{(i)} - \mu_{y^{(i)}} \right)^T \\ &= \frac{1}{n} \left[\sum_{i \in U_0} \left(\mathbf{x}^{(i)} \right) \left(\mathbf{x}^{(i)} \right)^T + \sum_{i \in U_1} \left(\mathbf{x}^{(i)} - \mu_1 \right) \left(\mathbf{x}^{(i)} - \mu_1 \right)^T \right] \end{aligned} \quad (9)$$

^a这四个方程的维数都是与相应参数相对应

GDA – 2-Classification Case – Prediction

Prediction: 给定一个 \mathbf{x} ，需要输出 $y \in \{0, 1\}$ ，而此时我们的输出为 $\arg \max \mathbb{P}(y|\mathbf{x})$ ，实际上只有如下两种可能：

$$\arg \max \{ \mathbb{P}(y = 0|\mathbf{x}; \mu_0, \mu_1, \Sigma, \phi), \mathbb{P}(y = 1|\mathbf{x}; \mu_0, \mu_1, \Sigma, \phi) \}$$

根据贝叶斯公式可以得到(证明见附录C，可作为练习)

$$\begin{aligned} \mathbb{P}(y = 1|\mathbf{x}; \mu_0, \mu_1, \Sigma, \phi) &= \frac{\mathbb{P}(\mathbf{x}|y = 1; \mu_0, \mu_1, \Sigma) \cdot \mathbb{P}(y = 1; \phi)}{\mathbb{P}(\mathbf{x}; \mu_0, \mu_1, \Sigma, \phi)} \\ &= \frac{1}{1 + \exp[-(\theta^T \mathbf{x} + \theta_0)]}, \quad \theta \in \mathbb{R}^d, \theta_0 \in \mathbb{R}, \text{均与参数 } \mu_0, \mu_1, \Sigma, \phi \text{ 相关} \end{aligned} \quad (10)$$

Decision Boundary: 不妨记 $a = \mathbb{P}(y = 0|\mathbf{x}; \mu_0, \mu_1, \Sigma, \phi)$, $b = \mathbb{P}(y = 1|\mathbf{x}; \mu_0, \mu_1, \Sigma, \phi)$ ，显然有 $a + b = 1$ ，那么

$$\max\{a, b\} = \begin{cases} a, & \text{if } a \geq 0.5 > b \\ b, & \text{if } b \geq 0.5 > a \end{cases}$$

当 $a = b$ 时，我们称此时的特征集合 $\{\mathbf{x} : \mathbb{P}(y = 0|\mathbf{x}) = 0.5\}$ 为决策边界(Decision Boundary)。

由式(10)可得：

$$\begin{aligned} \text{Decision boundary: } \frac{1}{1 + \exp[-(\theta^T \mathbf{x} + \theta_0)]} &= 0.5 \\ \Leftrightarrow \exp[-(\theta^T \mathbf{x} + \theta_0)] &= 1 \Leftrightarrow \theta^T \mathbf{x} + \theta_0 = 0 \end{aligned} \quad (11)$$

因此如果判定 \mathbf{x} 的类别是 $y = 1$ ，那么就等价于：

$$\mathbb{P}(y = 1|\mathbf{x}) > 0.5 \Leftrightarrow \theta^T \mathbf{x} + \theta_0 > 0 \quad (12)$$

事实上，当数据不满足高斯性时，也有可能最后得到相同形式的 Decision Boundary (10)。例如 $x \in \mathbb{N}$, $x|(y = i) \sim \text{Poisson}(\lambda_i)$, $\mathbb{P}(x = k) = e^{-\lambda_i} \frac{\lambda_i^k}{k!}$, $i \in \{0, 1\}$, $\mathbb{P}(y = 1) = \phi$ ，此时仍然可以得到式(10)。

Summary

Questions and Answers

Q1: 可以看到在二分类 GDA 中只需要求解 Decision Boundary = $\{\mathbf{x} : \theta^T \mathbf{x} + \theta_0 = 0\}$, 那么对于多分类也有 Decision Boundary 吗?

A1: 有, 但是会更加复杂, 需要仔细判定和设计.

Q2: 在逻辑回归中我们的形式和式(10)是一样的 (均为线性判别器), 那么这两个模型有什么区别?

A2:

	GDA(Generative)	Logistic(Discriminative)
Assumption	$\mathbf{x} (y = k) \sim \mathcal{N}(\boldsymbol{\mu}_k, \Sigma), k \in \{0, 1\}$ $y \sim \text{Bernoulli}$ (假设分布)	$\mathbb{P}(y = 1 \mathbf{x}) = \frac{1}{1 + \exp(-\theta^T \mathbf{x})}$ (直接假设模型)
Modeling	对 $\mathbb{P}(\mathbf{x}, y)$ 建模, 由条件概率公式有 $\mathbb{P}(\mathbf{x}, y) = \mathbb{P}(\mathbf{x} y)\mathbb{P}(y)$	仅对 $\mathbb{P}(y \mathbf{x})$ 建模
Process	模型先学参数 $\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi$, 再计算 得到 θ, θ_0	模型直接学习 θ

Table 1: Comparison between GDA and Logistic regression

High level perspective

可以看到相较于 Logistic regression, GDA 有更多的假设 (高斯性), 更多的正确的假设会带来更好的模型表现, 因为引入了正确的先验知识。然而, 引入假设都伴随着假设错误的风险, 因此也有风险使模型表现很糟糕。

Good: More assumption + Correct Assumption \Rightarrow Better performance

Risk: You might make wrong assumption! \Rightarrow Worse performance

不同的生成式学习算法(Generative learning algorithm)互相间性能的差异很大程度上是由其假设与问题的贴合性导致的; 生成式学习算法与判别式学习算法(Discriminative learning algorithm)性能的差异往往是由生成式学习算法做出了好的/不好的假设导致。

在解决问题时, 模型获取知识的来源有两个: 1. Assumption, 2. Data. 当数据足够多时, 有时做先验假设引入的风险反而使做假设引入知识变得不值得, 因此在现代的深度学习和大规模机器学习中, 数据量已经很大, 往往先进的算法已不再有很多的假设。但是在一些特殊领域, 例如医疗领域, 数据量并不大, 因此 GDA 这些方法仍然奏效。

此外, 不同的问题可能需要仔细地根据问题“定制”假设, 这需要一些行业经验才能做到。在现代的机器学习/深度学习中, GDA 的使用不如以前那么多, 因为现在很多任务甚至都没有标签, 例如只有图像或者无标记文本 (语言模型) 作为 \mathbf{x} 。

A Multivariate Gaussian Distribution

Multivariate Gaussian Distribution

高维高斯分布（Multivariate Gaussian Distribution）是高维空间中常见的概率分布。对于一个 d -维的随机向量 $\mathbf{x} = (x_1, x_2, \dots, x_d)^\top$ ，其概率密度函数（PDF）可以表示为：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

其中，


$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{x}] \in \mathbb{R}^d, \quad \Sigma = \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \in \mathbb{R}^{d \times d}$$

$\boldsymbol{\mu}$ 是均值向量，表示高斯分布的中心， Σ 是协方差矩阵，描述了各维度之间的线性依赖关系。具体来说，协方差矩阵 Σ 的元素 σ_{ij} 表示第 i 维与第 j 维的协方差。

协方差矩阵 Σ 不仅描述了各个维度之间的相关性，还决定了分布的形状。协方差矩阵是对角阵意味着各维度之间是独立的，分布在每一维度上是独立的高斯分布。若协方差矩阵是满秩的，则各维度之间可能存在相关性，分布的形状通常是椭圆形的。（见图A）

最大似然估计：在给定一组样本数据 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ 的情况下，高维高斯分布的最大似然估计（MLE）可以通过样本均值和样本协方差矩阵来得到。具体而言，均值向量和协方差矩阵的估计分别为：

$$\hat{\boldsymbol{\mu}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i, \quad \hat{\Sigma} = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top$$



$$\boldsymbol{\mu}_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \Sigma_1 = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix} \quad \boldsymbol{\mu}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} \quad \boldsymbol{\mu}_3 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \Sigma_3 = \begin{bmatrix} 1.5 & 0.3 \\ 0.3 & 2 \end{bmatrix}$$

Figure 2: Multivariate Gaussian Distribution

B Proof of the solutions of GDA(2-classification case)

Proof

我们的证明目标是式(7),(8),(9).

Proof. 对数似然函数 $l(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi)$ 为:

$$l(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) = \sum_{i=1}^n \left[\log \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)}) + \log \mathbb{P}(y^{(i)}) \right]$$

其中, $\mathbb{P}(\mathbf{x} | y = 0) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_0, \Sigma)$ 和 $\mathbb{P}(\mathbf{x} | y = 1) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_1, \Sigma)$, 分别是标签为0和1时特征的条件概率密度。 $\mathbb{P}(y = 0) = \phi$ 和 $\mathbb{P}(y = 1) = 1 - \phi$ 分别为标签为0和1时的先验概率。

我们需要根据类别 $y^{(i)}$ 来决定每个样本的似然:

$$\mathbb{P}(\mathbf{x}^{(i)} | y^{(i)} = 0) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0)^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0) \right)$$

$$\mathbb{P}(\mathbf{x}^{(i)} | y^{(i)} = 1) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_1)^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_1) \right)$$

因此, 总对数似然函数为:

$$l(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) = \sum_{i \in U_0} \left[\log \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)} = 0) + \log(1 - \phi) \right] + \sum_{j \in U_1} \left[\log \mathbb{P}(\mathbf{x}^{(j)} | y^{(j)} = 1) + \log(\phi) \right]$$

展开对数似然函数时, 我们需要处理每个样本对应的对数概率:

$$\log \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)} = 0) = -\frac{1}{2} \log |\Sigma| - \frac{d}{2} \log(2\pi) - \frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0)^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0)$$

$$\log \mathbb{P}(\mathbf{x}^{(i)} | y^{(i)} = 1) = -\frac{1}{2} \log |\Sigma| - \frac{d}{2} \log(2\pi) - \frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_1)^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_1)$$

因此, 完整的对数似然函数是:

$$\begin{aligned} l(\boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) &= -\frac{n}{2} \log |\Sigma| - \frac{nd}{2} \log(2\pi) + \sum_{i \in U_0} [\log(1 - \phi)] + \sum_{j \in U_1} [\log(\phi)] \\ &+ \sum_{i \in U_0} \left[-\frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0)^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0) \right] + \sum_{j \in U_1} \left[-\frac{1}{2} (\mathbf{x}^{(j)} - \boldsymbol{\mu}_1)^T \Sigma^{-1} (\mathbf{x}^{(j)} - \boldsymbol{\mu}_1) \right] \end{aligned}$$

① 对 ϕ 求导并令其为零:

$$\frac{\partial l}{\partial \phi} = -\frac{|U_0|}{1 - \phi} + \frac{|U_1|}{\phi} = 0 \Rightarrow \phi = \frac{|U_1|}{|U_0| + |U_1|} = \frac{|U_1|}{n} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y^{(i)} = 1)$$

② 对 $\boldsymbol{\mu}_0$ 求导并令其为零:

$$\frac{\partial l}{\partial \boldsymbol{\mu}_0} = \frac{\partial}{\partial \boldsymbol{\mu}_0} \sum_{i \in U_0} \left[-\frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0)^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0) \right] = \sum_{i \in U_0} \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_0) = 0$$

$$\Rightarrow \boldsymbol{\mu}_0 = \frac{1}{|U_0|} \sum_{i \in U_0} \mathbf{x}^{(i)}$$

③ 同理对 μ_0 求导并令其为零可得:

$$\mu_0 = \frac{1}{|U_1|} \sum_{j \in U_1} \mathbf{x}^{(j)}$$

④ 由于 $\frac{\partial |\Sigma|}{\partial \Sigma} = |\Sigma|(\Sigma^{-1})^T$, $\frac{\partial \ln |\Sigma|}{\partial \Sigma} = \Sigma^{-T}$, $\frac{\partial \Sigma^{-1}}{\partial \Sigma} = -\Sigma^{-1}\Sigma^{-1}$, 因此对 Σ 求导, 得到:

$$\frac{\partial l}{\partial \Sigma} = \frac{1}{2} \left(\sum_{i=1}^n \left[(\mathbf{x}^{(i)} - \mu_{y(i)})^T \Sigma^{-1} \Sigma^{-1} (\mathbf{x}^{(i)} - \mu_{y(i)}) \right] - n \Sigma^{-T} \right)$$

令其等于零, 得到:

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}^{(i)} - \mu_{y(i)})(\mathbf{x}^{(i)} - \mu_{y(i)})^T$$

即:

$$\Sigma = \frac{1}{n} \left[\sum_{i \in U_0} (\mathbf{x}^{(i)} - \mu_0)(\mathbf{x}^{(i)} - \mu_0)^T + \sum_{i \in U_1} (\mathbf{x}^{(i)} - \mu_1)(\mathbf{x}^{(i)} - \mu_1)^T \right]$$

□

C Proof of the decision boundary (10)

Proof of (10)

我们的证明目标是：

$$\begin{aligned}\mathbb{P}(y = 1|\mathbf{x}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi) &= \frac{\mathbb{P}(\mathbf{x}|y = 1; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma) \cdot \mathbb{P}(y = 1; \phi)}{\mathbb{P}(\mathbf{x}; \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi)} \\ &= \frac{1}{1 + \exp[-(\boldsymbol{\theta}^T \mathbf{x} + \theta_0)]}, \quad \boldsymbol{\theta} \in \mathbb{R}^d, \theta_0 \in \mathbb{R}, \text{ 均与参数 } \boldsymbol{\mu}_0, \boldsymbol{\mu}_1, \Sigma, \phi \text{ 相关}\end{aligned}\tag{13}$$

Proof. 根据贝叶斯公式和全概率公式，可以得到

$$\mathbb{P}(y = 1|\mathbf{x}) = \frac{\mathbb{P}(\mathbf{x}|y = 1)\mathbb{P}(y = 1)}{\mathbb{P}(\mathbf{x}|y = 1)\mathbb{P}(y = 1) + \mathbb{P}(\mathbf{x}|y = 0)\mathbb{P}(y = 0)}$$

同时已经假设

$$\mathbb{P}(y = 1) = \phi, \quad \mathbb{P}(y = 0) = 1 - \phi$$

$$\begin{aligned}\mathbb{P}(\mathbf{x}|y = 1) &= \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_1)\right) \\ \mathbb{P}(\mathbf{x}|y = 0) &= \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_0)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_0)\right)\end{aligned}$$

代入可得

$$\begin{aligned}\mathbb{P}(y = 1|\mathbf{x}) &= \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_1)\right) \cdot \phi}{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_1)\right) \cdot \phi + \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_0)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_0)\right) \cdot (1 - \phi)} \\ &= \frac{1}{1 + \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_0)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_0)\right) \cdot (1 - \phi)}{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_1)\right) \cdot \phi}} \\ &= \frac{1}{1 + \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_0)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_0) + \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) + \log \frac{1 - \phi}{\phi}\right)}\end{aligned}$$

这可以表示为：

$$\mathbb{P}(y = 1|\mathbf{x}) = \frac{1}{1 + \exp[-(\boldsymbol{\theta}^T \mathbf{x} + \theta_0)]}$$

其中 $\boldsymbol{\theta} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$ 和 $\theta_0 = \log \frac{\phi}{1 - \phi} + \frac{1}{2}(\boldsymbol{\mu}_0^T \Sigma^{-1} \boldsymbol{\mu}_0 - \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1)$. □

D Codes for Multivariate Gaussian Distribution

Multivariate Gaussian Distribution – Codes

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.stats import multivariate_normal
4 from mpl_toolkits.mplot3d import Axes3D
5
6 def plot_3d_gaussian(mu, cov, title="3D Gaussian Distribution", save_path=
    None):
7     """
8     Plot the 3D Gaussian distribution
9
10    Parameters:
11    mu: Mean, a list of length 2 [mu_x, mu_y]
12    cov: Covariance matrix, a 2x2 2D array
13    title: Title of the plot
14    save_path: Path to save the plot (optional)
15    """
16    # Generate mesh grid data
17    x = np.linspace(-5, 5, 1000)
18    y = np.linspace(-5, 5, 1000)
19    X, Y = np.meshgrid(x, y)
20
21    # Calculate the probability density of the 2D Gaussian distribution
22    pos = np.dstack((X, Y))
23    rv = multivariate_normal(mu, cov)
24    Z = rv.pdf(pos)
25
26    # Create a 3D surface plot
27    fig = plt.figure(figsize=(12, 10), dpi=200)
28    ax = fig.add_subplot(111, projection='3d')
29
30    # Plot a smooth surface
31    surf = ax.plot_surface(X, Y, Z, cmap="Spectral", edgecolor='none',
        alpha=0.8)
32
33    # Set title and labels
34    ax.set_title(title, fontsize=16, fontweight='bold')
35    ax.set_xlabel("X", fontsize=12)
36    ax.set_ylabel("Y", fontsize=12)
37    ax.set_zlabel("Density", fontsize=12)
38
39    # Set the view angle to avoid a flat view
40    ax.view_init(30, 30)
41
42    # Set the grid lines to be black
43    ax.grid(True, color='black') # Show grid lines
44    ax.xaxis._axinfo['grid'].update(color='black') # Grid lines for X axis
45    ax.yaxis._axinfo['grid'].update(color='black') # Grid lines for Y axis
46    ax.zaxis._axinfo['grid'].update(color='black') # Grid lines for Z axis
47
48    # Set the axis tick marks to be black
49    ax.tick_params(axis='both', direction='in', length=6, width=1, colors='
        black')
50
51    # Set the external border lines to be black
52    fig.patch.set_edgecolor('black') # External border lines of the figure
53    fig.patch.set_linewidth(2) # Set the thickness of the border
        lines
```

```

54
55     # Remove the background color of the panels, making them transparent
56     ax.xaxis.pane.fill = True # Transparent background for X axis
57     ax.yaxis.pane.fill = False # Transparent background for Y axis
58     ax.zaxis.pane.fill = False # Transparent background for Z axis
59
60     # ax.set_facecolor('none') # Uncomment to make the plotting area
        background transparent
61     # fig.patch.set_alpha(0) # Uncomment to make the figure background
        transparent
62
63     # fig.colorbar(surf, shrink=0.5, aspect=5) # Add a color bar (
        optional)
64
65     plt.show() # Display the plot
66
67     plt.draw() # Force redraw
68     plt.savefig(save_path)
69
70 # Example calls:
71 mu1 = [0, 0]
72 cov1 = [[1, 0], [0, 1]]
73 plot_3d_gaussian(mu1, cov1, title="Gaussian Distribution 1", save_path="
        gaussian-1.png")
74
75 mu2 = [0, 0]
76 cov2 = [[1, 0.8], [0.8, 1]]
77 plot_3d_gaussian(mu2, cov2, title="Gaussian Distribution 2", save_path="
        gaussian-2.png")
78
79 mu3 = [1, 2]
80 cov3 = [[1.5, 0.3], [0.3, 2]]
81 plot_3d_gaussian(mu3, cov3, title="Gaussian Distribution 3", save_path="
        gaussian-3.png")

```

First updated: December 16, 2024

Last updated: December 18, 2024

References