

**Subject:** Stanford CS229 Machine Learning, Lecture 13, GMM (EM)

**Date:** from August 26, 2025 to August 28, 2025

---

## **Contents**

<b>A</b>	<b>Proof of Eq. (1)</b>	<b>7</b>
<b>B</b>	<b>Proof of Theorem 1</b>	<b>7</b>

# Stanford CS229 Machine Learning, GMM (EM), 2022, Lecture 13

Link on YouTube: Stanford CS229 Machine Learning, GMM (EM), 2022, Lecture 13

## Introduction

### Introduction

本节内容介绍聚类算法中 GMM 算法及 EM 算法. 首先介绍两个基本工具: 凸性和 Jensen 不等式, 在此基础上, 通过 EM algorithm as MLE 介绍 EM 算法原理, 进一步通过 GMM as EM, 将 GMM 作为 EM 算法的实例介绍 GMM.


## Convexity and Jensen's inequality

### Convexity


**Definition 1. Convex and Nonconvex.** 称一个集合  $\Omega$  是凸的(convex), 若对于集合  $\Omega$  中任意两点  $a, b \in \Omega$ , 其二者之间的连线也均在该集合中. 数学上即:

$$\forall a, b \in \Omega, \quad (1 - \lambda)a + b \in \Omega, \quad \lambda \in [0, 1].$$

如图2所示, 图1a 中集合为凸的, 但图1b 中集合为非凸的.



(a) Convex




(b) Nonconvex

Figure 1: Comparison between convex and nonconvex.


**Definition 2. Convex Function.** 对于函数  $f$ , 定义其 graph 为  $G_f = \{(x, y) : y \geq f(x)\}$ , 则称  $f$  为凸函数(convex function) 若其 graph 是凸的. 数学上即 (推导见附录A) :

$$\forall \lambda \in [0, 1], \lambda f(a) + (1 - \lambda)f(b) \geq f(z), \quad z = \lambda a + (1 - \lambda)b \quad (1)$$

如图2a 中函数为凸函数, 其中每一条弦 (即两点连线) 均在函数之上(every chord is beyond the function); 图2b 中为非凸函数, 不能保证每一条弦均在函数之上.



(a) Convex function



(b) Nonconvex function

Figure 2: Comparison between convex and nonconvex function

**Theorem 1.** 若函数  $f$  的二阶导恒大于等于 0, 即  $f''(x) \geq 0, \forall x$ , 则  $f$  为凸函数.

*Proof.* 见附录B □

**Definition 3. Strictly Convex.** 称  $f$  是严格凸函数(strictly convex), 若  $f''(x) > 0, \forall x \in \text{dom}$ .

**Definition 4. Concave Function.** 相对于凸函数, 称函数  $g$  为凹函数(concave function) 若  $-g$  为凸函数.

### Jensen's inequality

**Theorem 2. Jensen's Inequality.** 若  $f$  为凸函数, 则

$$\mathbb{E}[f(x)] \geq f(\mathbb{E}(x)). \quad (2)$$

例如,  $P(x = a) = \lambda, P(x = b) = 1 - \lambda$ , 则  $\mathbb{E}[f(x)] = \lambda f(a) + (1 - \lambda)f(b), f(\mathbb{E}[x]) = f(\lambda a + (1 - \lambda)b)$ , 因此结合凸函数定义, 显然 Jensen's inequality 成立.

## EM Algorithm as MLE

### EM Algorithm as MLE

给定数据  $\{x_i\}_{i=1}^n$  和参数  $\theta$ , 标准的最大似然估计(maximum likelihood estimation, MLE) 形式为:

$$l(\theta) = \sum_{i=1}^n \log P(x_i; \theta), \quad (3)$$

在已知信息的基础上, 若希望对问题引入一些特定 (但可能未知) 的结构时就会引入 latent variable, 例如 Lecture 12 的光子接收器中对每一个光子的来源比例做出  $\Theta$  的结构性质假设. 此时  $P(x_i; \theta)$  变为:

$$P(x; \theta) = \sum_z P(x, z; \theta). \quad (4)$$

### EM Algorithm: Idea

如图3所示, 由于原目标函数  $l(\theta)$  较难优化 (一般无凸、凹性), 因此 EM 算法首先在  $\theta^{(t)}$  处使用存在凸/凹性的新目标函数  $L_t(\theta)$  替换  $l(\theta)$ , 因此比  $l(\theta)$  更容易优化, 接着再更新  $\theta^{(t+1)} = \arg \max_{\theta} L_t(\theta)$ . 其中替代函数(surrogate)  $L_t(\theta)$  需要满足两点性质:

1. *Low bound:*  $L_t(\theta) \leq l(\theta)$ , 即替代函数是原目标函数的下界
2. *Tight:*  $L_t(\theta^{(t)}) = l(\theta^{(t)})$ , 即替代函数与原目标函数在当前迭代点的函数值相等

因此, EM 算法简单来说分为两步:

1. (E-step): 给定  $\theta^{(t)}$  寻找  $L_t(\theta)$
2. (M-step): 给定  $L_t(\theta)$ , 更新  $\theta^{(t+1)} = \arg \max_{\theta} L_t(\theta)$




Figure 3: EM algorithm.

### EM Algorithm: Select $L_t$

**Lower bounds:** 在引入 latent variable  $z$  后,  $\log P(x; \theta)$  变为:

$$\log P(x; \theta) = \log \sum_z P(x, z; \theta) = \log \sum_z \frac{Q(z) \cdot P(x, z; \theta)}{Q(z)}, \forall Q(z), \quad (5)$$

其中  $Q(z)$  为一离散分布, 满足  $\sum_z Q(z) = 1, Q(z) \geq 0$ .

式(5) 可以进一步改写, 并应用 Jensen's inequality 可得:

$$\begin{aligned} \log \sum_z \frac{Q(z) \cdot P(x, z; \theta)}{Q(z)} &= \log \mathbb{E}_{z \sim Q(z)} \frac{P(x, z; \theta)}{Q(z)} \geq \mathbb{E}_{z \sim Q(z)} \left[ \log \frac{P(x, z; \theta)}{Q(z)} \right] \\ &= \sum_z Q(z) \cdot \log \frac{P(x, z; \theta)}{Q(z)} \end{aligned} \quad (6)$$

**Note 1.** 注意此时满足  $\sum_z Q(z) = 1, Q(z) \geq 0$  的  $Q(z)$  都满足式(6), 这样我们就获得了  $l(\theta)$  的下界集合, 集合中的函数  $L$  均满足  $L(\theta) \leq l(\theta)$ .

**Note 2.** 式(6)中  $\sum_z Q(z) \cdot \log \frac{P(x, z; \theta)}{Q(z)}$  被称为 **Evidence-based lower bound (ELBO)**, 即

$$ELBO(x, Q, z) = \sum_z Q(z) \cdot \log \frac{P(x, z; \theta)}{Q(z)}. \quad (7)$$

因此有

$$l(\theta) \geq \sum_{i=1}^n ELBO(x^{(i)}, Q^{(i)}; \theta). \quad (8)$$

在获得了  $l(\theta)$  的下界集合后, 符合要求的  $L_t$  还需要其满足 *Tight* 的性质.

**Make it tight.** 从式(6)可以看到, 不等号是由求  $\log \frac{P(x, z; \theta)}{Q(z)}$  的期望产生的, 因此为消除不等号可以令其为独立于  $z$  的常数, 即令  $\log \frac{P(x, z; \theta)}{Q(z)} = C$ . 此时令  $Q(z) = P(z|x; \theta)$  就有:

$$\log \frac{P(x, z; \theta)}{Q(z)} = \log \frac{P(z|x; \theta) \cdot P(x; \theta)}{P(z|x; \theta)} = \log P(x; \theta). \quad (9)$$

由于消除了关于  $z$  的随机性, 此时就有

$$l(\theta^{(t)}) = \sum_{i=1}^n \log P(x_i; \theta^{(t)}) = \sum_{i=1}^n ELBO(x^{(i)}, Q^{(i)}; \theta^{(t)}), \quad (10)$$

其中  $Q^{(i)} = P(z^{(i)}|x^{(i)}; \theta^{(t)})$ .

**Note 3.** 由于  $Q^{(i)}$  的选取与  $x, \theta$  相关, 因此针对  $\theta^{(i)}$  点处的替代函数而言, 因为选取了  $Q^{(i)} = P(z|x^{(i)}; \theta^{(i)})$ , 因此只有  $\theta^{(i)}$  处满足等式, 而其他  $\theta_\beta$  处只有  $Q = P(z|x^{(i)}; \theta_\beta)$  才满足等式, 因此只能满足不等式  $l(\theta_\beta) \geq \sum_{i=1}^n ELBO(x^{(i)}, Q^{(i)}; \theta^{(i)})$ .

**Note 4.**  $z^{(i)}$  是对问题作一个潜在的结构假设, 例如在 Lecture 12 的光子实验中, 对于每个 sample  $i$ ,  $z^{(i)}$  是对其来源的假设, 例如如果目前有两种来源, 那么可以假设  $P(z^{(i)} = 1) = \phi_1, P(z^{(i)} = 2) = \phi_2$ , 这就是对此问题的一种潜在的结构假设.

### EM Algorithm: Conclusion

综上所述 EM 算法分为如下两步:

1. (E-step): 给定  $\theta^{(t)}$ , 令  $Q^{(i)} = P(z^{(i)}|x^{(i)}; \theta), i = 1, \dots, n$
2. (M-step): 给定  $L_t(\theta)$ , 更新  $\theta^{(t+1)} = \arg \max_{\theta} L_t(\theta) = \sum_{i=1}^n ELBO(x^{(i)}, Q^{(i)}; \theta)$
1. 由于  $\theta^{(t+1)} = \arg \max_{\theta} L_t(\theta) = \sum_{i=1}^n ELBO(x^{(i)}, Q^{(i)}; \theta)$ , 因此  $l(\theta^{(t+1)}) \geq l(\theta^{(t)})$ , 故 EM 算法一定会收敛/ 终止.
2. 但是由于每次更新都选择了更优的参数, 因此并不能够跳出局部最优点, 故不能保证最终能收敛至全局最优.

## EM for GMM

### EM for GMM

**Recall.** 根据 Lecture 12 中 GMM 模型:

$$P(x^{(i)}, z^{(i)}) = P(x^{(i)}|z^{(i)}) \cdot P(z^{(i)}), \quad (11)$$

其中  $z^{(i)} \sim \text{Multinomial}(\Phi), \phi_i \geq 0, \sum_i \phi_i = 1, P(x^{(i)}|z^{(i)}) \sim \mathcal{N}(\mu_j, \sigma_j^2)$ .

记  $Q^{(i)}(z^{(i)}) = P(z^{(i)}|x^{(i)}; \theta)$ , 则此时 EM 算法中 M-step 为:

$$\max_{\Theta} \sum_{i=1}^n \sum_{z^{(i)}} Q^{(i)}(z^{(i)}) \log \frac{P(x^{(i)}, z^{(i)}; \theta)}{Q^{(i)}(z^{(i)})}, \quad (12)$$

其中  $\Theta = \{\Phi, \mu, \Sigma\}$ .

**Derivative for  $\mu_j$ .** 记  $f_i(\theta) = \sum_{z^{(i)}} Q^{(i)}(z^{(i)}) \log \frac{P(x^{(i)}, z^{(i)}; \theta)}{Q^{(i)}(z^{(i)})}$ ,  $w_j^{(i)} = Q^{(i)}(z^{(i)} = j) = P(z^{(i)} = j|x^{(i)}; \theta)$ , 则:

$$f_i(\theta) = \sum_j w_j^{(i)} \log \frac{\frac{1}{2\pi|\Sigma|^{1/2}} \exp\{-\frac{1}{2}(x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)\} \phi_j}{w_j^{(i)}}, \quad (13a)$$

$$\nabla_{\mu_j} \sum_{i=1}^n f_i(\theta) = \sum_{i=1}^n \nabla_{\mu_j} (w_j^{(i)} - \frac{1}{2}(x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)) = -\frac{1}{2} \sum_{i=1}^n w_j^{(i)} \Sigma_j^{-1} (x^{(i)} - \mu_j). \quad (13b)$$

令梯度  $\nabla_{\mu_j} \sum_{i=1}^n f_i(\theta) = 0$ ，即可以得到：

$$\mu_j = -\frac{\sum_i w_j^{(i)} (x^{(i)} - \mu_j)}{\sum_i w_j^{(i)}}. \quad (14)$$

**Derivative for  $\phi_j$ .** 由于  $\phi_j$  需要满足约束条件  $\sum_j \phi_j = 1, \phi_j \geq 0$ ，因此根据 Lagrangian，重新构造损失函数为<sup>a</sup>：

$$\sum_{i=1}^n f_i(\theta) = \sum_{i=1}^n w_j^{(i)} \log \phi_j + \lambda (\sum_j \phi_j - 1) \quad (15)$$

再对  $\phi_j$  求导可得：

$$\nabla_{\phi_j} \sum_{i=1}^n f_i(\theta) = \sum_{i=1}^n w_j^{(i)} \nabla_{\phi_j} \log \phi_j + \nabla_{\phi_j} \lambda (\sum_j \phi_j - 1) = \sum_{i=1}^n \frac{w_j^{(i)}}{\phi_j} + \lambda. \quad (16)$$

令  $\nabla_{\phi_j} \sum_{i=1}^n f_i(\theta) = 0$ ，得

$$\sum_j \phi_j = 1 = -\frac{1}{\lambda} \sum_{i,j} w_j^{(i)} = -\frac{n}{\lambda} \Rightarrow \lambda = -n. \quad (17)$$

---

<sup>a</sup>这里为方便书写，省略了一些与求导无关的项。

## A Proof of Eq. (1)

### Proof of Eq. (1)

*Proof.* 根据凸函数定义, 有:

$$\forall \lambda \in [0, 1], \lambda(a, f(a)) + (1 - \lambda)(b, f(b)) \in \Omega \quad (18)$$

因此定义  $z = \lambda a + (1 - \lambda)b$ , 则有

$$(z, \lambda f(a) + (1 - \lambda)f(b)) \in \Omega \Rightarrow \lambda f(a) + (1 - \lambda)f(b) \geq f(z) \quad (19)$$

□

## B Proof of Theorem 1

### Proof of Theorem 1

**Proposition 1.**

$$f''(x) \geq 0, \forall x \Rightarrow f \text{ is convex.} \quad (20)$$

*Proof.* 由 Taylor expansion 可得,  $\forall z \in [a, b]$ :

$$\begin{aligned} f(a) &= f(z) + f'(\alpha)(a - z) + f''(\alpha)(a - z)^2, \alpha \in [a, z] \\ f(b) &= f(z) + f'(\beta)(b - z) + f''(\beta)(b - z)^2, \beta \in [z, b], \end{aligned} \quad (21)$$

因此有

$$\lambda f(a) + (1 - \lambda)f(b) = f(z) + O(z) + C \geq f(z) \quad (22)$$

□

## References