

# Stanford CS229 Machine Learning, Introduction, 2022, Lecture 1

Link on YouTube: Stanford CS229 Machine Learning, Introduction, 2022, Lecture 1

## History of Machine Learning

机器学习(Machine Learning)这个词语最早是由Arthur Samuel (1959)提出的: *Machine Learning is the field of study that gives the computer the ability to learn **without being explicitly programmed***[1].

机器“学习”这个概念最早由Tom Mitchell (1998)定义: *a computer program is said to learn from **experience E** with respect to some class of **tasks T** and **performance measure P**, if its performance at tasks in T, as measured by P, **improves** with experience E*[2].

机器学习根据所解决的任务可以简单地分类为有监督学习(Supervised Learning), 无监督学习(Unsupervised Learning)和强化学习(Reinforcement Learning), 但是他们之间并非完全分开, 现在已经更把他们当作解决问题的工具和方法, 他们之间互有交叉。

## Supervised Learning

### Example of house price prediction

以房价预测任务为例, 给定数据集<sup>a</sup>(data set)  $\{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$ , 该集合中的元素 $(x^{(k)}, y^{(k)})$ 被称为样本(samples), 样本由数据-标签对构成, 其中 $x^{(k)}$ 为房子面积,  $y^{(k)}$ 为对应的房价。我们的任务就是根据数据集学习如何根据房子面积预测房价。一种解决方式是使用一次(线性, linear)/二次(quadratic)函数去拟合数据集。

继续考虑更复杂的情况, 例如我们的数据中不仅仅包含房屋面积, 还包括例如生活区面积(living size)等等特征, 此时就希望根据更复杂的数据集 $\{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(n)}, y^{(n)})\}$ 进行预测<sup>b</sup>, 其中 $\mathbf{x}^{(i)} = (x_1^{(i)}, x_2^{(i)}) \in \mathbb{R}^2$ 。数学形式上, 我们就是希望找到这样的映射:

$$\mathbb{R}^2 \rightarrow \mathbb{R}, \quad \underbrace{(\text{size, lot size})}_{\text{features/input}} \rightarrow \underbrace{\text{price}}_{\text{label/output/supervision}}$$

同样地还可以考虑更高维度的 $\mathbf{x} \in \mathbb{R}^d$ 。后续会讨论数据特征是无限维的情况, 也会讨论如何从数据的多种特征中筛选出“好”的特征。

<sup>a</sup>用Tom Mitchell的话来说数据集就是experience

<sup>b</sup>实际上是更高维度的数据

## Classification of supervised learning

根据标签(label)的类型, 有监督学习可以分为回归(regression)和分类(classification)两类:

	variable	example
Regression	Continuous	price prediction)
Classification	Discrete	predicting types of residence

Table 1: Regression vs Classification

## Unsupervised Learning

## Examples

**Clustering:** 仍然以房价预测为例，无监督学习与有监督学习最大的不同就是在无监督学习中数据集没有标签(label)，即 $y^{(k)}$ 。一种做法是将使用算法将相似的数据进行归类，如果新的数据与某一类最“相似”，那么我们就可以将他们归为一类，例如后面的k-means聚类(Clustering)。

**Clustering Genes:** 聚类也可以用于生物信息学，例如基因聚类(Clustering Genes)[3]，将不同的个体的基因进行向量化数值表示后进行使用聚类，就可以将个体分组。

**Latent Semantic Analysis (LSA):** 潜在语义分析，在有很多的文件(documents)组成的语料库中，可以针对每个文件中出现的某些代表性词语(words)对文件进行聚类，从而能够发现主题相似/相同的文件。更多细节可以参见wikepedia——潜在语义学, Topic detection in a document-word matrix.gif

**Word Embeddings:** 词嵌入是一种将词编码为向量的机器学习算法，在自然语言处理中非常重要，代表算法有Word2vec[4], GloVe[5]。在进行词嵌入后，词语编码为向量，词与词之间的关系编码为向量空间中的方向：

$$\text{word} \xrightarrow{\text{encode}} \text{vector}, \quad \text{relation} \xrightarrow{\text{encode}} \text{direction}$$

例如考虑每个国家的首都：在嵌入后的向量空间中，意大利指向其首都罗马的方向与法国指向其首都巴黎的方向基本为一个方向，因此如果想要寻找中国的首都，就在此方向上对城市进行搜索，大概率能够找到北京。更多细节可以参见wikepedia——词嵌入, Word2vec

**Large Language Models, LLM:** 暂略，重要些不言而喻。由于本人数学专业，分享一篇近期Apple研究人员的结果：GSM-Symbolic[6]。他们的结果表明伴随着训练，大模型的数学推理能力并不能被证明得到了提高。

## Reinforcement Learning

### Learning to make sequential decisions

无论是在监督学习还是无监督学习中，我们的目的都很清晰，大体上都是在对 $y$ 进行预测，但是在强化学习中，我们仅仅只能从环境中获得反馈(甚至这种反馈不能是及时的反馈)，根据反馈做出决策(这个决策也可能不是立即可以在获得反馈后做出的)以达到一个长期的目的。




Figure 1: Reinforcement Learning

例如，著名的AlphaGo[7]，在围棋比赛中，最终目的是赢下比赛，这是一个长远的目标，中途需要一步一步的落子以达成目的，并且每一步落子后有一步的反馈，根据这个反馈能够指导下一步的落子。

## References

- [1] Arthur L Samuel. Some studies in machine learning using the game of checkers. ii—recent progress. *IBM Journal of research and development*, 11(6):601–617, 1967.
- [2] Tom M Mitchell and Tom M Mitchell. *Machine learning*, volume 1. McGraw-hill New York, 1997.
- [3] Su-In Lee, Dana Pe’er, Aimée M Dudley, George M Church, and Daphne Koller. Identifying regulatory mechanisms using individual variation reveals key role for chromatin modification. *Proceedings of the National Academy of Sciences*, 103(38):14062–14067, 2006.
- [4] Tomas Mikolov. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.
- [5] Jeffrey Pennington, Richard Socher, and Christopher D Manning. Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1532–1543, 2014.
- [6] Iman Mirzadeh, Keivan Alizadeh, Hooman Shahrokhi, Oncel Tuzel, Samy Bengio, and Mehrdad Farajtabar. Gsm-symbolic: Understanding the limitations of mathematical reasoning in large language models. *arXiv preprint arXiv:2410.05229*, 2024.
- [7] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *nature*, 529(7587):484–489, 2016.