

2 Lecture 2: Bellman Equation

2.1 State Value


Return Calculating

回报 (return) 定义为未来 reward 的累积量, 可以度量 policy 的好坏. 由于 reward 等都可能带有随机性 (写为大写字母 R), 因此 return 本质也是一个随机变量, 一般使用带折扣因子 γ 的 discounted return 防止累和发散:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \quad (2.1)$$

Return 有多种计算方式, 此处介绍两种且不考虑随机性, 即 trajectory 已确定: ① 根据定义 (discounted) 累和. ② 自助法 (bootstrapping), 即借助对未来的估计来估计现在: 由于每个 state 的 return 都依赖于下一个 return: $v_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = r_{t+1} + \gamma v_{t+1}$, 因此可以将所有 state 的 return 串联成矩阵形式统一求解.

Example 2.1. 根据定义, 图 2.1 中所有 discounted return 的计算方式如式 (2.2) 所示:



$$\begin{aligned} v_1 &= r_1 + \gamma r_2 + \gamma^2 r_3 + \dots = r_1 + \gamma (r_2 + \gamma r_3 + \dots) = r_1 + \gamma v_2, \\ v_2 &= r_2 + \gamma r_3 + \gamma^2 r_4 + \dots = r_2 + \gamma (r_3 + \gamma r_4 + \dots) = r_2 + \gamma v_3, \\ v_3 &= r_3 + \gamma r_4 + \gamma^2 r_1 + \dots = r_3 + \gamma (r_4 + \gamma r_1 + \dots) = r_3 + \gamma v_4, \\ v_4 &= r_4 + \gamma r_1 + \gamma^2 r_2 + \dots = r_4 + \gamma (r_1 + \gamma r_2 + \dots) = r_4 + \gamma v_1. \end{aligned} \quad (2.2)$$

Figure 2.1: Illustrating example


虽然四个变量相互关联构成循环看似不可解, 但实际上写成如下线性矩阵-向量方程 (linear matrix-vector equation) 后只需求逆矩阵即可:

$$\underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_v = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_r + \gamma \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}}_P \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_v \Rightarrow v = r + \gamma P v \Rightarrow v = (I - \gamma P)^{-1} r. \quad (2.3)$$

State Value

由于 return G_t 是随机变量, 因此一次 rollout / sampled trajectory 得到的 return 也只是一个样本. 因此为整体上比较 policy 的好坏, 一个直接的想法就是在期望意义上进行比较.

Example 2.2. 图 2.2 的例子中, 在初始点 s_1 此 policy 有 p_1 概率选择向右、有 p_2 概率向下 ($p_1 + p_2 = 1$), 因此一个简单的想法就是求期望, 如式 (2.4) 所示.



$$\begin{aligned} v_1 &= p_1 (r_{11} + \gamma r_2 + \gamma^2 r_3 + \gamma^3 r_3 + \dots) + p_2 (r_{12} + \gamma r_4 + \gamma^2 r_3 + \gamma^3 r_3 + \dots) \\ &\stackrel{p_1+p_2=1}{=} p_1 (r_{11} + \gamma r_2) + p_2 (r_{12} + \gamma r_4) + r_3 (\gamma^2 + \gamma^3 + \dots). \end{aligned} \quad (2.4)$$

Figure 2.2: Illustrating example

State Value. State value 用于评价 policy π 从 state s 出发的表现, 衡量的依据是该 state 处 return 的期望值, 其全称为 **state value function**:

$$v_\pi(s) \triangleq \mathbb{E}[G_t | S_t = s] \quad (2.5)$$

Note 2.1. ① State value 是 state s 的函数, 并且依赖于 policy π . ② State value 并不能直接评价 policy 的全局表现, 只能在固定 s 下进行比较. ③ 当无随机性即考虑确定性 trajectory 时, return 的累和 G_t 就与 state value 相同.

Definition 2.1. 给定两 policy π_1, π_2 , 若对于 state s 有 $v_{\pi_1}(s) \geq v_{\pi_2}(s)$ 则称 policy π_1 在 state s 处优于 π_2 . 若对于任意 state s 都有 $v_{\pi_1}(s) \geq v_{\pi_2}(s)$ 则称 policy π_1 全局优于 π_2 .

2.2 Bellman Equation

Bellman Equation (Element-wise Form)

虽然每个 state 的 state value 中包含了未知的下一步 state value 而无法单独求解，但从 Example 2.1 中可以看出将所有 state 联系后可通过方程组求解。Bellman Equation (BE) 就是描述不同 state 的 state value 关系的工具。

BE 的核心思想是利用 return 的递归结构将当前状态价值拆解为“下一步奖励+ $\gamma \times$ 下一状态价值”，从而将不同 state 联系起来。对于一个 trajectory $S_t \xrightarrow{A_t} R_{t+1}, S_{t+1} \xrightarrow{A_{t+1}} R_{t+2}, S_{t+2}, \dots$ ，discounted return 可以写为：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \dots) = \underbrace{R_{t+1}}_{\text{immediate reward}} + \gamma \cdot \underbrace{G_{t+1}}_{\text{future reward}}. \quad (2.6)$$

代入 state value 定义式 (2.5) 后可以得到：

$$v_\pi(s) = \mathbb{E}[G_t | S_t = s] = \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] = \underbrace{\mathbb{E}[R_{t+1} | S_t = s]}_{\text{①}} + \gamma \underbrace{\mathbb{E}[G_{t+1} | S_t = s]}_{\text{②}}. \quad (2.7)$$

其中 ① 为 **mean of immediate reward**：

$$\mathbb{E}[R_{t+1} | S_t = s] = \sum_{a \in \mathcal{A}(s)} \pi(a | s) \mathbb{E}[R_{t+1} | S_t = s, A_t = a] = \sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{r \in \mathcal{R}(s, a)} p(r | s, a) \cdot r. \quad (2.8)$$

② 为 **mean of future reward**：

$$\begin{aligned} \mathbb{E}[G_{t+1} | S_t = s] &\stackrel{\text{law of total expectation}}{=} \sum_{s' \in \mathcal{S}} \mathbb{E}[G_{t+1} | S_t = s, S_{t+1} = s'] p(s' | s) \stackrel{\text{Markov decision process property}}{=} \sum_{s' \in \mathcal{S}} \mathbb{E}[G_{t+1} | S_{t+1} = s'] p(s' | s) \\ &= \sum_{s' \in \mathcal{S}} v_\pi(s') p(s' | s) \stackrel{\text{law of total expectation}}{=} \sum_{s' \in \mathcal{S}} v_\pi(s') \sum_{a \in \mathcal{A}(s)} p(s' | s, a) \pi(a | s). \end{aligned} \quad (2.9)$$

将式 (2.8) (2.9) 代回式 (2.7) 中可以得到 element-wise form **Bellman Equation**：

$$\begin{aligned} v_\pi(s) &= \mathbb{E}[R_{t+1} | S_t = s] + \gamma \mathbb{E}[G_{t+1} | S_t = s] = \underbrace{\sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{r \in \mathcal{R}(s, a)} p(r | s, a) r}_{\text{mean of immediate rewards}} + \gamma \underbrace{\sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{s' \in \mathcal{S}} p(s' | s, a) v_\pi(s')}_{\text{mean of future rewards}} \\ &= \sum_{a \in \mathcal{A}(s)} \pi(a | s) \left[\sum_{r \in \mathcal{R}(s, a)} p(r | s, a) r + \gamma \sum_{s' \in \mathcal{S}} p(s' | s, a) v_\pi(s') \right], \quad \forall s \in \mathcal{S}. \end{aligned} \quad (2.10)$$

Note 2.2. ① Bellman Equation (2.10) 实际是将 state s 的 state value 用所有 state 进行表示，因此描述了不同 state 的 state value function 间的联系。② 虽然式 (2.10) 表面只有一个表达式，但通过遍历 $s \in \mathcal{S}$ 可以得到一族共 $|\mathcal{S}|$ 个方程。③ 求解 Bellman Equation 的过程又被称为 *policy evaluation*，因为实际就是计算所有 state value、对 policy 进行评估。

根据全概率公式 (law of total probability)，Bellman Equation (2.10) 也可以写为：

$$v_\pi(s) \frac{p(r | s, a) = \sum_{s' \in \mathcal{S}} p(s', r | s, a)}{p(s' | s, a) = \sum_{r \in \mathcal{R}} p(s', r | s, a)} \sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) [r + \gamma v_\pi(s')]. \quad (2.11)$$

如果在某些问题中 reward 只与 s' 相关，那么上述 Bellman Equation 又可以进一步写为

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in \mathcal{S}} p(s' | s, a) [r(s') + \gamma v_\pi(s')]. \quad (2.12)$$

Bellman Equation (Matrix-vector Form)

Bellman Equation (2.10) 实际包括 $|S|$ 个方程，将它们组合起来就可以显式得到 matrix-vector form 的 BE。首先为书写方便，对式 (2.10) 进行如下改写：

$$v_{\pi}(s) = \underbrace{\sum_{a \in A(s)} \pi(a|s) \sum_{r \in \mathcal{R}(s,a)} p(r|s,a)r}_{\text{mean of immediate rewards}} + \gamma \underbrace{\sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} p(s'|s,a)v_{\pi}(s')}_{\text{mean of future rewards}} = r_{\pi}(s) + \gamma \sum_{s'} p_{\pi}(s'|s)v_{\pi}(s'), \quad (2.13)$$

其中 $r_{\pi}(s)$ 为 mean of immediate rewards, $p_{\pi}(s'|s)$ 为在 policy π 下 state 由 s 转变为 s' 的概率 (式 (2.9)):

$$r_{\pi}(s) \triangleq \sum_a \pi(a|s) \sum_r p(r|s,a)r, \quad p_{\pi}(s'|s) \triangleq \sum_a \pi(a|s)p(s'|s,a). \quad (2.14)$$

从而对于 n 个 state 的 state space $S = \{s_1, s_2, \dots, s_n\}$, n 个 Bellman Equation 可写为:

$$v_{\pi}(s_i) = r_{\pi}(s_i) + \gamma \sum_{s_j} p_{\pi}(s_j | s_i) v_{\pi}(s_j), \quad i = 1, 2, \dots, n \Rightarrow \mathbf{v}_{\pi} = \mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} \mathbf{v}_{\pi}, \quad (2.15)$$

其中 $\mathbf{v}_{\pi} = [v_{\pi}(s_1), \dots, v_{\pi}(s_n)]^T \in \mathbb{R}^n$, $\mathbf{r}_{\pi} = [r_{\pi}(s_1), \dots, r_{\pi}(s_n)]^T \in \mathbb{R}^n$, $\mathbf{P}_{\pi} \in \mathbb{R}^{n \times n}$, $[\mathbf{P}_{\pi}]_{ij} = p_{\pi}(s_j | s_i)$ 为状态转移矩阵 (state transition matrix), 满足 ① $0 < [\mathbf{P}_{\pi}]_{ij} = p_{\pi}(s_j | s_i) \leq 1$ ② $\mathbf{P}_{\pi} \mathbf{1} = \mathbf{1}$, 其中 $\mathbf{1} = [1, 1, \dots, 1]^T$.

将式 (2.15) 写成矩阵形式可以得到:

$$\underbrace{\begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ \vdots \\ v_{\pi}(s_n) \end{bmatrix}}_{\mathbf{v}_{\pi}} = \underbrace{\begin{bmatrix} r_{\pi}(s_1) \\ r_{\pi}(s_2) \\ \vdots \\ r_{\pi}(s_n) \end{bmatrix}}_{\mathbf{r}_{\pi}} + \gamma \underbrace{\begin{bmatrix} p_{\pi}(s_1|s_1) & \cdots & p_{\pi}(s_{n-1}|s_1) & p_{\pi}(s_n|s_1) \\ p_{\pi}(s_1|s_2) & \cdots & p_{\pi}(s_{n-1}|s_2) & p_{\pi}(s_n|s_2) \\ \vdots & \ddots & \vdots & \vdots \\ p_{\pi}(s_1|s_n) & \cdots & p_{\pi}(s_{n-1}|s_n) & p_{\pi}(s_n|s_n) \end{bmatrix}}_{\mathbf{P}_{\pi}} \underbrace{\begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ \vdots \\ v_{\pi}(s_n) \end{bmatrix}}_{\mathbf{v}_{\pi}}. \quad (2.16)$$

Solve the Bellman Equation

① 求解 Bellman Equation (2.15) (2.16) 最直接的方式就是直接求其闭式解 (closed-form solution):

$$\mathbf{v}_{\pi} = (\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \mathbf{r}_{\pi}. \quad (2.17)$$

矩阵 $\mathbf{I} - \gamma \mathbf{P}_{\pi}$ 具有如下性质: (1) 可逆^a, 因此保证了解的存在性. (2) $(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \geq_{\text{elem}} \mathbf{I}$. 因为 $(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} = \mathbf{I} + \gamma \mathbf{P}_{\pi} + \gamma^2 \mathbf{P}_{\pi}^2 + \cdots \geq_{\text{elem}} \mathbf{I}$. (3) $(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \mathbf{r} \geq \mathbf{r} \geq 0, \forall \mathbf{r} \geq 0$. (直接利用性质 2 即可).

Note 2.3. 性质 (2) ① 保证 state value $\mathbf{v}_{\pi}$ 至少和 reward $\mathbf{r}_{\pi}$ 具有相同的趋势. 即如果 reward $\mathbf{r}_{\pi}$ 非负那么 state value $\mathbf{v}_{\pi}$ 也必然非负. ② 可以用于构造收敛性证明. 如值迭代 (value iteration) 或策略迭代 (policy iteration) 算法中常用 $\mathbf{v}_k \leq \mathbf{v}_{k+1}$ 来证明值函数单调收敛于最优 state value. 性质 (3) 进一步加强了 state value function 的单调性. 即如果 reward $\mathbf{r}_{\pi}$ 非负, 那么其影响不会被折扣因子 γ 和转移矩阵 $\mathbf{P}_{\pi}$ 降到 0, 而是至少保持原有的奖励大小.

Note 2.4. 虽然解析解形式直接, 但数值上大规模矩阵求逆很困难, 需要使用特殊的数值方法 (且仍然难以求解).

② 求解 Bellman Equation (2.15) (2.16) 的另一种方式是通过迭代法找其迭代解 (iterative solution):

$$\mathbf{v}_{k+1} = \mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} \mathbf{v}_k, k = 0, 1, 2, \dots \quad (2.18)$$

可以证明^b 上述迭代过程一定收敛 (证明过程详见附录 A):

$$\mathbf{v}_k \xrightarrow{k \rightarrow \infty} \mathbf{v}_{\pi} = (\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \mathbf{r}_{\pi}. \quad (2.19)$$

^a 证明需要使用 Gershgorin circle theorem, 详见附录 A

^b 如果熟悉的话这其实就是一个不动点迭代的证明, 使用 Banach 不动点定理

2.3 Action Value

Action Value

Action value 也是强化学习中的一个重要概念，其定义需要和 state value 相联系。Action value 是指在某 state 下采取相应的某 action 后能够获得的 average return，其依赖 state, action 和 policy:

$$q_{\pi}(s, a) \triangleq \mathbb{E}[G_t | S_t = s, A_t = a]. \quad (2.20)$$

State value 与 action value 的区别在于 state value 是指 agent 从一个 state 出发能得到的 average return，而 action value 是指 agent 从一个 state 出发并且做出一个 action 后能得到的 average return:

$$v_{\pi}(s) = \mathbb{E}[G_t | S_t = s], \quad q_{\pi}(s, a) \triangleq \mathbb{E}[G_t | S_t = s, A_t = a]. \quad (2.21)$$

实际上 action value 与 state value 像一个硬币的两面，可以相互推导:

$$\underbrace{\mathbb{E}[G_t | S_t = s]}_{v_{\pi}(s)} = \sum_a \underbrace{\mathbb{E}[G_t | S_t = s, A_t = a]}_{q_{\pi}(s, a)} \pi(a|s) = \sum_a \pi(a|s) \underbrace{\left[\sum_r p(r|s, a)r + \gamma \sum_{s'} p(s'|s, a)v_{\pi}(s') \right]}_{q_{\pi}(s, a)} \quad (2.22a)$$

$$\Rightarrow v_{\pi}(s) = \sum_a \pi(a|s) q_{\pi}(s, a).$$

$$q_{\pi}(s, a) = \sum_r p(r|s, a)r + \gamma \sum_{s'} p(s'|s, a)v_{\pi}(s'). \quad (2.22b)$$

Examples in LLM

在 token 级建模中，可以把语言生成写成 Markov Decision Process (MDP): ① State $s_t = (x, y_{<t})$: prompt + 已经生成的 token ② Action $a_t = y_t$: 下一个 token ③ Policy $\pi_{\theta}(a_t | s_t)$: 语言模型的 next-token distribution ④ Reward: reward model 分数、规则奖励、工具执行结果或人工反馈. 于是

$$V^{\pi}(x, y_{<t}) = \mathbb{E}_{\pi}[\text{从此前缀继续生成的最终奖励}], \quad Q^{\pi}(x, y_{<t}, y_t) = \mathbb{E}_{\pi}[\text{选择该token 后的最终奖励}].$$

A Proof of Lecture 2

Proof of Eq. (2.19)

$$\mathbf{v}_k \xrightarrow{k \rightarrow \infty} \mathbf{v}_\pi = (\mathbf{I} - \gamma \mathbf{P}_\pi)^{-1} \mathbf{r}_\pi$$

Proof. 首先定义残差 $\delta_k = \mathbf{v}_k - \mathbf{v}_\pi$, 我们只需要证明 $\delta_k \rightarrow \mathbf{0}$ 即可. 将 $\mathbf{v}_{k+1} = \delta_{k+1} + \mathbf{v}_\pi$ 和 $\mathbf{v}_k = \delta_k + \mathbf{v}_\pi$ 代入 $\mathbf{v}_{k+1} = \mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_k$ 中得到

$$\delta_{k+1} = -\mathbf{v}_\pi + \mathbf{r}_\pi + \gamma \mathbf{P}_\pi \delta_k + \gamma \mathbf{P}_\pi \mathbf{v}_\pi = \gamma \mathbf{P}_\pi \delta_k - \mathbf{v}_\pi + (\mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_\pi) \stackrel{\mathbf{v}_\pi = \mathbf{r}_\pi + \gamma \mathbf{P}_\pi \mathbf{v}_\pi}{=} \gamma \mathbf{P}_\pi \delta_k.$$

递归展开可得:

$$\delta_{k+1} = \gamma \mathbf{P}_\pi \delta_k = \gamma^2 \mathbf{P}_\pi^2 \delta_{k-1} = \dots = \gamma^{k+1} \mathbf{P}_\pi^{k+1} \delta_0.$$

由于 $\mathbf{P}_\pi$ 是行随机矩阵, $0 \leq [\mathbf{P}_\pi]_{ij} = p_\pi(s_j | s_i) \leq 1$, 即 $0 \leq [\mathbf{P}_\pi^k]_{ij} \leq 1$, 因此 $\|\mathbf{P}_\pi\|_\infty \leq 1$, 故:

$$\|\mathbf{P}_\pi \mathbf{x}\|_\infty \leq \|\mathbf{P}_\pi\|_\infty \cdot \|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_\infty, \forall \mathbf{x}.$$

因此有

$$\|\delta_{k+1}\|_\infty = \left\| \gamma^{k+1} \mathbf{P}_\pi^{k+1} \delta_0 \right\|_\infty \leq \gamma^{k+1} \|\delta_0\|_\infty \xrightarrow[0 \leq \gamma < 1]{k \rightarrow \infty} 0 \Rightarrow \mathbf{v}_k \rightarrow \mathbf{v}_\pi.$$

□

Reversibility of $\mathbf{I} - \gamma \mathbf{P}_\pi$

$\mathbf{I} - \gamma \mathbf{P}_\pi$ 可逆

Proof. 令 $\mathbf{A} \triangleq \mathbf{I} - \gamma \mathbf{P}_\pi$, 根据 Gershgorin circle theorem A.1, 矩阵 $\mathbf{A}$ 的所有特征值均位于至少一个 Gershgorin disc 中, 其中第 i 个 Gershgorin disc 的圆心 a_{ii} 和半径 R_i 分别为

$$a_{ii} = [\mathbf{I} - \gamma \mathbf{P}_\pi]_{ii} = 1 - \gamma p_\pi(s_i | s_i), \quad R_i = \sum_{j \neq i} |a_{ij}| = \sum_{j \neq i} |-\gamma p_\pi(s_j | s_i)| = \gamma \sum_{j \neq i} p_\pi(s_j | s_i) = \gamma (1 - p_\pi(s_i | s_i)).$$

对于第 i 个 Gershgorin disc 中的任意一点 $z \in D(a_{ii}, R_i)$, 其实部 $\text{Re}(z)$ 满足

$$\text{Re}(z) \geq a_{ii} - R_i = 1 - \gamma p_\pi(s_i | s_i) - \gamma (1 - p_\pi(s_i | s_i)) = 1 - \gamma > 0, \quad 0 \leq \gamma < 1$$

因此, 所有 Gershgorin discs 均严格位于复平面的右半平面, 且不包含原点. 于是 0 不可能是 $\mathbf{I} - \gamma \mathbf{P}_\pi$ 的特征值, 即 $\det(\mathbf{I} - \gamma \mathbf{P}_\pi) \neq 0$. 因此 $\mathbf{I} - \gamma \mathbf{P}_\pi$ 可逆.

□

Theorem A.1 (Gershgorin circle theorem). 令 $\mathbf{A} = [a_{ij}] \in \mathbb{C}^{n \times n}$ 为复矩阵, R_i 为第 i 行除对角元外元素之和:

$$R_i \triangleq \sum_{j \neq i} |a_{ij}|$$

令 $D(a_{ii}, R_i) \triangleq \{z \in \mathbb{C} : |z - a_{ii}| \leq R_i\} \subseteq \mathbb{C}$ 表示中心为 a_{ii} , 半径为 R_i 的闭圆盘(disc), 称之为 Gershgorin disc. 那么, $\mathbf{A}$ 的每个特征值均位于至少一个 Gershgorin disc 中, 即

$$\sigma(\mathbf{A}) \subseteq \bigcup_{i=1}^n D(a_{ii}, R_i),$$

其中 $\sigma(\mathbf{A})$ 表示 $\mathbf{A}$ 的特征值集合.