

## 2 Lecture 2: Bellman Equation

### 2.1 State Value


#### Return Calculating

回报 (**return**) 定义为未来 reward 的累积量, 可以度量 policy 的好坏. 由于 reward 等都可能带有随机性 (写为大写字母  $R$ ), 因此 return 本质也是一个随机变量, 一般使用带折扣因子  $\gamma$  的 **discounted return** 防止累和发散:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \quad (2.1)$$

Return 有多种计算方式, 此处介绍两种且不考虑随机性, 即 **trajectory** 已确定: ① 根据定义 (**discounted**) 累和. ② 自助法 (**bootstrapping**), 即借助对未来的估计来估计现在: 由于每个 state 的 return 都依赖于下一个 return:  $g_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = r_{t+1} + \gamma g_{t+1}$ , 因此可以将所有 state 的 return 串联成矩阵形式统一求解.

**Example 2.1.** 根据定义, 图 2.1 中所有 **discounted return** 的计算方式如式 (2.2) 所示:



$$\begin{aligned} g_1 &= r_1 + \gamma r_2 + \gamma^2 r_3 + \dots = r_1 + \gamma (r_2 + \gamma r_3 + \dots) = r_1 + \gamma g_2, \\ g_2 &= r_2 + \gamma r_3 + \gamma^2 r_4 + \dots = r_2 + \gamma (r_3 + \gamma r_4 + \dots) = r_2 + \gamma g_3, \\ g_3 &= r_3 + \gamma r_4 + \gamma^2 r_1 + \dots = r_3 + \gamma (r_4 + \gamma r_1 + \dots) = r_3 + \gamma g_4, \\ g_4 &= r_4 + \gamma r_1 + \gamma^2 r_2 + \dots = r_4 + \gamma (r_1 + \gamma r_2 + \dots) = r_4 + \gamma g_1. \end{aligned} \quad (2.2)$$

Figure 2.1: Illustrating example


虽然四个变量相互关联构成循环看似不可解, 但实际上写成如下线性矩阵-向量方程 (**linear matrix-vector equation**) 后只需求逆矩阵即可:

$$\underbrace{\begin{bmatrix} g_1 \\ g_2 \\ g_3 \\ g_4 \end{bmatrix}}_g = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_r + \underbrace{\begin{bmatrix} \gamma g_2 \\ \gamma g_3 \\ \gamma g_4 \\ \gamma g_1 \end{bmatrix}}_{\gamma P g} = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_r + \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}}_P \underbrace{\begin{bmatrix} g_1 \\ g_2 \\ g_3 \\ g_4 \end{bmatrix}}_g \Rightarrow g = r + \gamma P g \Rightarrow g = (I - \gamma P)^{-1} r. \quad (2.3)$$

#### State Value

由于 return  $G_t$  是随机变量, 因此一次 rollout / sampled trajectory 得到的 return 也只是一个样本. 因此为整体上比较 policy 的好坏, 一个直接的想法就是在期望意义上进行比较.

**Example 2.2.** 图 2.2 的例子中, 在初始点  $s_1$  此 policy 有  $p_1$  概率选择向右、有  $p_2$  概率向下 ( $p_1 + p_2 = 1$ ), 因此一个简单的想法就是求期望, 如式 (2.4) 所示.



$$\begin{aligned} g_1 &= p_1 (r_{11} + \gamma r_2 + \gamma^2 r_3 + \gamma^3 r_3 + \dots) + p_2 (r_{12} + \gamma r_4 + \gamma^2 r_3 + \gamma^3 r_3 + \dots) \\ &= \frac{p_1 + p_2 = 1}{1} p_1 (r_{11} + \gamma r_2) + p_2 (r_{12} + \gamma r_4) + r_3 (\gamma^2 + \gamma^3 + \dots). \end{aligned} \quad (2.4)$$

Figure 2.2: Illustrating example

**State Value.** State value 用于评价 policy  $\pi$  从 state  $s$  出发持续执行的表现, 衡量的依据是该 state 处持续执行 policy  $\pi$  后 return 的期望值, 其全称为 **state value function**:

$$v_\pi(s) \triangleq \mathbb{E}[G_t | S_t = s] \quad (2.5)$$

**Note 2.1.** ① State value 是 state  $s$  的函数, 并且依赖于 policy  $\pi$ . ② State value 并不能直接评价 policy 的全局表现, 只能在固定  $s$  下进行比较. ③ 当无随机性即考虑确定性 trajectory 时, return 的累和  $G_t$  就与 state value 相同. ④ State value 的定义要求 state  $s$  作为评价起点, 不一定意味着真实任务必须从  $s$  启动.

**Definition 2.1.** 给定两 policy  $\pi_1, \pi_2$ , 若对于 state  $s$  有  $v_{\pi_1}(s) \leq v_{\pi_2}(s)$  则称 policy  $\pi_1$  在 state  $s$  处不劣于  $\pi_2$ . 若对于任意 state  $s$  都有  $v_{\pi_1}(s) \leq v_{\pi_2}(s)$  则称 policy  $\pi_1$  全局劣于  $\pi_2$ .

## 2.2 Bellman Equation

### Bellman Equation (Element-wise Form)

虽然每个 state 的 state value 中包含了未知的下一步 state value 而无法单独求解, 但从 Example 2.1 中可以看出将所有 state 联系后可通过方程组求解. **Bellman Equation (BE)** 就是描述不同 state 的 state value 关系的工具.

BE 的核心思想是利用 return 的递归结构将当前状态价值拆解为 “下一步奖励 +  $\gamma \times$  下一状态价值”, 从而将不同 state 联系起来. 对于一个 trajectory  $S_t \xrightarrow{A_t} R_{t+1}, S_{t+1} \xrightarrow{A_{t+1}} R_{t+2}, S_{t+2}, \dots$ , discounted return 可以写为:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \dots) = \underbrace{R_{t+1}}_{\text{immediate reward}} + \gamma \cdot \underbrace{G_{t+1}}_{\text{future reward}}. \quad (2.6)$$

代入 state value 定义式 (2.5) 后可以得到:

$$v_\pi(s) = \mathbb{E}[G_t | S_t = s] = \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] = \underbrace{\mathbb{E}[R_{t+1} | S_t = s]}_{\text{①}} + \gamma \underbrace{\mathbb{E}[G_{t+1} | S_t = s]}_{\text{②}}. \quad (2.7)$$

其中 ① 为 **mean of immediate reward**:

$$\mathbb{E}[R_{t+1} | S_t = s] = \sum_{a \in \mathcal{A}(s)} \pi(a | s) \mathbb{E}[R_{t+1} | S_t = s, A_t = a] = \sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{r \in \mathcal{R}(s, a)} p(r | s, a) \cdot r. \quad (2.8)$$

② 为 **mean of future reward**:

$$\begin{aligned} \mathbb{E}[G_{t+1} | S_t = s] &\stackrel{\text{law of total expectation}}{=} \sum_{s' \in \mathcal{S}} \mathbb{E}[G_{t+1} | S_t = s, S_{t+1} = s'] p_\pi(s' | s) \stackrel{\text{Markov decision process property}}{=} \sum_{s' \in \mathcal{S}} \mathbb{E}[G_{t+1} | S_{t+1} = s'] p_\pi(s' | s) \\ &= \sum_{s' \in \mathcal{S}} v_\pi(s') p_\pi(s' | s) \stackrel{\text{law of total expectation}}{=} \sum_{s' \in \mathcal{S}} v_\pi(s') \sum_{a \in \mathcal{A}(s)} p(s' | s, a) \pi(a | s). \end{aligned} \quad (2.9)$$

将式 (2.8) (2.9) 代回式 (2.7) 中可以得到 element-wise form **Bellman Equation**:

$$\begin{aligned} v_\pi(s) &= \mathbb{E}[R_{t+1} | S_t = s] + \gamma \mathbb{E}[G_{t+1} | S_t = s] = \underbrace{\sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{r \in \mathcal{R}(s, a)} p(r | s, a) r}_{\text{mean of immediate rewards}} + \gamma \underbrace{\sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{s' \in \mathcal{S}} p(s' | s, a) v_\pi(s')}_{\text{mean of future rewards}} \\ &= \sum_{a \in \mathcal{A}(s)} \pi(a | s) \left[ \sum_{r \in \mathcal{R}(s, a)} p(r | s, a) r + \gamma \sum_{s' \in \mathcal{S}} p(s' | s, a) v_\pi(s') \right], \quad \forall s \in \mathcal{S}. \end{aligned} \quad (2.10)$$

**Note 2.2.** ① Bellman Equation (2.10) 实际是将 state  $s$  的 state value 用所有 state 进行表示, 因此描述了不同 state 的 state value function 间的联系. ② 虽然式 (2.10) 表面只有一个表达式, 但通过遍历  $s \in \mathcal{S}$  可以得到一族共  $|\mathcal{S}|$  个方程. ③ 求解 Bellman Equation 的过程又被称为 *policy evaluation*, 因为实际就是计算所有 state value、对 policy 进行评估.

根据全概率公式 (law of total probability), Bellman Equation (2.10) 也可以写为:

$$v_\pi(s) \stackrel{p(r|s,a)=\sum_{s' \in \mathcal{S}} p(s', r|s, a)}{=} \sum_{a \in \mathcal{A}(s)} \pi(a | s) \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) [r + \gamma v_\pi(s')]. \quad (2.11)$$

如果在某些问题中 reward 只与  $s'$  相关, 那么上述 Bellman Equation 又可以进一步写为

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in \mathcal{S}} p(s' | s, a) [r(s') + \gamma v_\pi(s')]. \quad (2.12)$$

## Bellman Equation (Matrix-vector Form)

Bellman Equation (2.10) 实际包括  $|\mathcal{S}|$  个方程，将它们组合起来就可以显式得到 matrix-vector form 的 BE。首先为书写方便，对式 (2.10) 进行如下改写：

$$v_{\pi}(s) = \underbrace{\sum_{a \in \mathcal{A}(s)} \pi(a|s) \sum_{r \in \mathcal{R}(s,a)} p(r|s,a)r}_{\text{mean of immediate rewards}} + \gamma \underbrace{\sum_{a \in \mathcal{A}(s)} \pi(a|s) \sum_{s' \in \mathcal{S}} p(s'|s,a)v_{\pi}(s')}_{\text{mean of future rewards}} = r_{\pi}(s) + \gamma \sum_{s'} p_{\pi}(s'|s)v_{\pi}(s'), \quad (2.13)$$

其中  $r_{\pi}(s)$  为 mean of immediate rewards,  $p_{\pi}(s'|s)$  为在 policy  $\pi$  下 state 由  $s$  转变为  $s'$  的概率 (式 (2.9)):

$$r_{\pi}(s) \triangleq \sum_a \pi(a|s) \sum_r p(r|s,a)r, \quad p_{\pi}(s'|s) \triangleq \sum_a \pi(a|s)p(s'|s,a). \quad (2.14)$$

从而对于  $n$  个 state 的 state space  $\mathcal{S} = \{s_1, s_2, \dots, s_n\}$ ,  $n$  个 Bellman Equation 可写为:

$$v_{\pi}(s_i) = r_{\pi}(s_i) + \gamma \sum_{s_j} p_{\pi}(s_j | s_i) v_{\pi}(s_j), \quad i = 1, 2, \dots, n \Rightarrow \mathbf{v}_{\pi} = \mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} \mathbf{v}_{\pi}, \quad (2.15)$$

其中  $\mathbf{v}_{\pi} = [v_{\pi}(s_1), \dots, v_{\pi}(s_n)]^T \in \mathbb{R}^n$ ,  $\mathbf{r}_{\pi} = [r_{\pi}(s_1), \dots, r_{\pi}(s_n)]^T \in \mathbb{R}^n$ ,  $\mathbf{P}_{\pi} \in \mathbb{R}^{n \times n}$ ,  $[\mathbf{P}_{\pi}]_{ij} = p_{\pi}(s_j | s_i)$  为状态转移矩阵 (state transition matrix), 满足 ①  $0 \leq [\mathbf{P}_{\pi}]_{ij} = p_{\pi}(s_j | s_i) \leq 1$  ②  $\mathbf{P}_{\pi} \mathbf{1} = \mathbf{1}$ , 其中  $\mathbf{1} = [1, 1, \dots, 1]^T$ .

将式 (2.15) 写成矩阵形式可以得到:

$$\underbrace{\begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ \vdots \\ v_{\pi}(s_n) \end{bmatrix}}_{\mathbf{v}_{\pi}} = \underbrace{\begin{bmatrix} r_{\pi}(s_1) \\ r_{\pi}(s_2) \\ \vdots \\ r_{\pi}(s_n) \end{bmatrix}}_{\mathbf{r}_{\pi}} + \gamma \underbrace{\begin{bmatrix} p_{\pi}(s_1|s_1) & \cdots & p_{\pi}(s_{n-1}|s_1) & p_{\pi}(s_n|s_1) \\ p_{\pi}(s_1|s_2) & \cdots & p_{\pi}(s_{n-1}|s_2) & p_{\pi}(s_n|s_2) \\ \vdots & \ddots & \vdots & \vdots \\ p_{\pi}(s_1|s_n) & \cdots & p_{\pi}(s_{n-1}|s_n) & p_{\pi}(s_n|s_n) \end{bmatrix}}_{\mathbf{P}_{\pi}} \underbrace{\begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ \vdots \\ v_{\pi}(s_n) \end{bmatrix}}_{\mathbf{v}_{\pi}}. \quad (2.16)$$

## Solve the Bellman Equation

① 求解 Bellman Equation (2.15) (2.16) 最直接的方式就是直接求其闭式解 (closed-form solution):

$$\mathbf{v}_{\pi} = (\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \mathbf{r}_{\pi}. \quad (2.17)$$

矩阵  $\mathbf{I} - \gamma \mathbf{P}_{\pi}$  具有如下性质: (1) 可逆<sup>a</sup>, 因此保证了解的存在性. (2)  $(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \geq_{\text{elem}} \mathbf{I}$ . 因为  $(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} = \mathbf{I} + \gamma \mathbf{P}_{\pi} + \gamma^2 \mathbf{P}_{\pi}^2 + \cdots \geq_{\text{elem}} \mathbf{I}$ . (3)  $(\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \mathbf{r} \geq \mathbf{r} \geq 0, \forall \mathbf{r} \geq 0$ . (直接利用性质 2 即可).

**Note 2.3.** 性质 (2) ① 保证 state value  $\mathbf{v}_{\pi}$  至少和 reward  $\mathbf{r}_{\pi}$  具有相同的趋势. 即如果 reward  $\mathbf{r}_{\pi}$  非负那么 state value  $\mathbf{v}_{\pi}$  也必然非负. ② 可以用于构造收敛性证明. 如值迭代 (value iteration) 或策略迭代 (policy iteration) 算法中常用  $\mathbf{v}_k \leq \mathbf{v}_{k+1}$  来证明值函数单调收敛于最优 state value. 性质 (3) 进一步加强了 state value function 的单调性. 即如果 reward  $\mathbf{r}_{\pi}$  非负, 那么其影响不会被折扣因子  $\gamma$  和转移矩阵  $\mathbf{P}_{\pi}$  降到 0, 而是至少保持原有的奖励大小.

**Note 2.4.** 虽然解析解形式直接, 但数值上大规模矩阵求逆很困难, 需要使用特殊的数值方法 (且仍然难以求解).

② 求解 Bellman Equation (2.15) (2.16) 的另一种方式是通过迭代法找其迭代解 (iterative solution):

$$\mathbf{v}_{k+1} = \mathbf{r}_{\pi} + \gamma \mathbf{P}_{\pi} \mathbf{v}_k, \quad k = 0, 1, 2, \dots \quad (2.18)$$

可以证明<sup>b</sup> 上述迭代过程一定收敛 (证明过程详见附录 A):

$$\mathbf{v}_k \xrightarrow{k \rightarrow \infty} \mathbf{v}_{\pi} = (\mathbf{I} - \gamma \mathbf{P}_{\pi})^{-1} \mathbf{r}_{\pi}. \quad (2.19)$$

<sup>a</sup> 证明需要使用 Gershgorin circle theorem, 详见附录 A

<sup>b</sup> 如果熟悉的话这其实就是一个不动点迭代的证明, 使用 Banach 不动点定理

## 2.3 Action Value

### Action Value

Action value 也是强化学习中的一个重要概念，其定义需要和 state value 相联系。Action value 是指在某 state 下采取相应的某 action 后能够获得的 average return，其依赖 state, action 和 policy:

$$q_{\pi}(s, a) \triangleq \mathbb{E}[G_t | S_t = s, A_t = a]. \quad (2.20)$$

State value 与 action value 的区别在于 state value 是指 agent 从一个 state 出发能得到的 average return，而 action value 是指 agent 从一个 state 出发并且做出一个 action 后能得到的 average return:

$$v_{\pi}(s) = \mathbb{E}[G_t | S_t = s], \quad q_{\pi}(s, a) \triangleq \mathbb{E}[G_t | S_t = s, A_t = a]. \quad (2.21)$$

实际上 action value 与 state value 像一个硬币的两面，可以相互推导:

$$\underbrace{\mathbb{E}[G_t | S_t = s]}_{v_{\pi}(s)} = \sum_a \underbrace{\mathbb{E}[G_t | S_t = s, A_t = a]}_{q_{\pi}(s, a)} \pi(a|s) = \sum_a \pi(a|s) \underbrace{\left[ \sum_r p(r|s, a)r + \gamma \sum_{s'} p(s'|s, a)v_{\pi}(s') \right]}_{q_{\pi}(s, a)} \quad (2.22a)$$

$$\Rightarrow v_{\pi}(s) = \sum_a \pi(a|s) q_{\pi}(s, a).$$

$$q_{\pi}(s, a) = \sum_r p(r|s, a)r + \gamma \sum_{s'} p(s'|s, a)v_{\pi}(s'). \quad (2.22b)$$

### Examples in LLM

在 token 级建模中，可以把语言生成写成 Markov Decision Process (MDP): ① State  $s_t = (x, y_{<t})$ : prompt + 已经生成的 token ② Action  $a_t = y_t$ : 下一个 token ③ Policy  $\pi_{\theta}(a_t | s_t)$ : 语言模型的 next-token distribution ④ Reward: reward model 分数、规则奖励、工具执行结果或人工反馈. 于是

$$V^{\pi}(x, y_{<t}) = \mathbb{E}_{\pi}[\text{从此前缀继续生成的最终奖励}], \quad Q^{\pi}(x, y_{<t}, y_t) = \mathbb{E}_{\pi}[\text{选择该token 后的最终奖励}].$$