

5 Lecture 5: Stochastic Approximation and Stochastic Gradient Descent

5.1 Robbins-Monro Algorithm (RM Algorithm)

Incremental update

许多算法中都涉及到收集样本并对某些值进行估计，常规的做法是使用非增量式计算 (**non-incremental**)，即等到 N 个样本采样完成后再进行下一步，但这往往会降低算法效率。一种替代方式是使用增量式 (**incremental**) 更新，即立即使用新的采样数据迭代更新目标量，这样虽然在算法初期损失了部分精度但无需等待、提升了算法效率。

Example 5.1 (Mean Estimation). 在求经验期望时，非增量式计算会采样 N 个样本 $\{x_i\}_{i=1}^N$ 并统一计算：

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N} \sum_{i=1}^N x_i \quad (5.1)$$

但若规定：

$$w_{k+1} = \frac{1}{k} \sum_{i=1}^k x_i, \quad k = 1, 2, \dots, N-1, \quad w_k = \frac{1}{k-1} \sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \dots, N. \quad (5.2)$$

那么就能得到如下 *incremental* 更新格式：

$$w_{k+1} = \frac{1}{k} \sum_{i=1}^k x_i = \frac{1}{k} \left(\sum_{i=1}^{k-1} x_i + x_k \right) = \frac{1}{k} ((k-1)w_k + x_k) = w_k - \frac{1}{k}(w_k - x_k) \quad (5.3)$$

一般地，上述 *mean estimation* 的 *incremental* 格式可以总结为：

$$w_{k+1} = w_k - \alpha_k (w_k - x_k), \quad (5.4)$$

其中 $\alpha_k > 0$ ，后续将说明当其满足一些条件时，仍然会保证收敛： $x_k \xrightarrow{k \rightarrow \infty} \mathbb{E}[X]$ 。

Robbins-Monro algorithm

Robbins-Monro (RM) 算法是随机近似算法 (Stochastic approximation, SA) 中的一种。SA 常用于方程求根问题和优化问题，相较于牛顿法、梯度下降等算法，SA 可以在函数表达式未知 (但可获得有噪输出) 的情况下使用迭代更新的方式求解问题。上述 *incremental* 格式的 *mean estimation* 和随机梯度下降 (SGD) 都是 RM 算法的特殊情况。

Problem statement. 考虑一个方程的求零点问题 $f(w) = 0$ ，其中 $f(w)$ 为表达式未知的黑盒 (black box) (例如神经网络就可以抽象为 $f(w) = y$ 的形式，但是 g 的形式是未知的)，我们只能获得有噪输出

$$\tilde{f}(w, \eta) = f(w) + \eta.$$

其中 η 为观测噪声。


Note 5.1. 实际上优化问题和方程的求根问题都是 $f(w) = 0$ 的形式：

$$\text{优化问题: } f(w) = \nabla_w J(w) = 0 \quad \text{求根问题: } f(w) = c \Rightarrow \tilde{f} = f(w) - c = 0$$

Robbins-Monro (RM) algorithm. RM 算法通过如下迭代方式逼近 $f(w) = 0$ 的真实解：

$$w_{k+1} = w_k - a_k \tilde{f}(w_k, \eta_k), \quad k = 1, 2, 3, \dots, \quad (5.5)$$

其中 w_k 为对解的第 k 次估计。可以看出 RM 算法只依赖于输入和输出数据：① Input sequence: $\{w_k\}$ ② Noisy output sequence: $\{\tilde{f}(w_k, \eta_k)\}$ 。一个简单的求解 $f(x) = x^3 - 2 = 0$ 的根的数值案例如下图所示，初始猜测 $x_0 = 0$ 。



Robbins-Monro Algorithm – Convergence Analysis

Theorem 5.1 (Robbins-Monro theorem). 对于 Robbins-Monro 算法, 若 ① $\forall w, 0 < c_1 \leq \nabla_w f(w) \leq c_2$ (梯度假设) ② $\sum_{k=1}^{\infty} a_k = \infty, \sum_{k=1}^{\infty} a_k^2 < \infty$ (系数假设) ③ $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0, \mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$ (误差假设), 其中 $\mathcal{H}_k = \{w_k, w_{k-1}, \dots\}$. 设方程 $f(w) = 0$ 的根为 w^* , 满足 $f(w^*) = 0$, 那么 w_k 以概率1收敛 (with probability 1, w.p.1) 至 w^* .

Note 5.2. 对于上述三个条件, 有如下详细解读:

1. ① 梯度假设

- (a) 梯度 $\nabla_w f(w) > 0$, 即原函数单调上升, 保证了方程 $f(w) = 0$ 若有解则一定唯一. 这一条件一般可以满足, 例如当处理优化问题时, $f(w)$ 本身即梯度, $f(w) > 0$ 表示原函数是凸的, 即较常见的凸优化问题.
- (b) $\nabla_w f(w) \leq c_2$ 说明梯度有界, 不过不满足此条件算法有时也能够收敛.

2. ② 系数假设

- (a) $\sum_{k=1}^{\infty} a_k^2 < \infty$ 表明 $a_k \xrightarrow{k \rightarrow \infty} 0$. 这可以保证 $w_{k+1} - w_k = -a_k \tilde{f}(w_k, \eta_k) \xrightarrow{k \rightarrow \infty} 0$, 即收敛.
- (b) $\sum_{k=1}^{\infty} a_k = \infty$ 表明 $a_k \xrightarrow{k \rightarrow \infty} 0$ 没有那么快. 将所有递推式 $w_{k+1} = w_k - a_k \tilde{f}(w_k, \eta_k)$ 两端累和可以得到

$$w_1 - w_{\infty} = \sum_{k=1}^{\infty} a_k \tilde{f}(w_k, \eta_k)$$

若 $\sum_{k=1}^{\infty} a_k < \infty$, 由于 $\tilde{f}$ 有界, 那么 $|\sum_{k=1}^{\infty} a_k \tilde{f}(w_k, \eta_k)|$ 有界, 这就要求初始猜测 w_1 不能距 w^* 过远, 反之若收敛至零较慢则可放宽对初始猜测的要求.

- (c) 取 $a_k = \frac{1}{k}$ 是可以满足要求的, 因为 $\sum_{k=1}^n \frac{1}{k} \xrightarrow{n \rightarrow \infty} \infty, \sum_{k=1}^{\infty} \frac{1}{k^2} < \infty$, 原因在于:

$$\lim_{n \rightarrow \infty} \left(\sum_{k=1}^n \frac{1}{k} - \ln n \right) = \kappa, \ln n \xrightarrow{n \rightarrow \infty} \infty \Rightarrow \sum_{k=1}^n \frac{1}{k} \xrightarrow{n \rightarrow \infty} \infty, \sum_{k=1}^{\infty} \frac{1}{k^2} = \frac{\pi^2}{6} < \infty \text{ (Basel problem)}. \quad (5.6)$$

其中 $\kappa \approx 0.577$ 为 Euler-Mascheroni 常数^a.

- (d) 常见的做法并非令系数为 $\frac{1}{k}$, 因为当 k 较大时, 后面的数据在算法中起到的作用被无限缩小, 这并不是我们想要的, 因此常见的做法是开始时赋予较小的值再慢慢减小但不至于趋于 0

3. ③ – 测量误差假设. 这里并不要求 η 满足高斯性, 常见的做法是取 $\{\eta_k\}$ 来自一个 i.i.d. 的随机序列, 满足 $\mathbb{E}[\eta_k | \mathcal{H}_k] = \mathbb{E}[\eta_k] = 0, \mathbb{E}[\eta_k^2 | \mathcal{H}_k] = \mathbb{E}[\eta_k^2] < \infty$.

^a欧拉-马斯刻若尼常数是一个数学常数, 定义为调和级数与自然对数的差值

Robbins-Monro algorithm – Applying to mean estimation

定义 $f(w) \triangleq w - \mathbb{E}[X]$, 我们需要求出 $f(w) = 0$ 的解 w^* , 可以定义有噪观测为 $\tilde{f}(w, x) \triangleq w - x$, 那么可以得到:

$$\tilde{f}(w, \eta) = (w - \mathbb{E}[X]) + (\mathbb{E}[X] - x) \triangleq f(w) + \eta \quad (5.7)$$

其中 $\eta \triangleq \mathbb{E}[X] - x$, x 是对 X 的采样. 代入 RM 算法 (5.5) 中就得:

$$w_{k+1} = w_k - \alpha_k \tilde{f}(w_k, \eta_k) = w_k - \alpha_k (w_k - x_k) \quad (5.8)$$

再套用 Theorem 5.1 即可得到相应的收敛性结论, 并且此收敛性对于 X 的分布没有任何假设. 其收敛性分析也可以使用 Dvoretzky's convergence theorem, 详细证明见附录C.

5.2 Dvoretzky's Convergence Theorem

Dvoretzkys convergence theorem

Dvoretzkys convergence theorem 是 SA 领域的经典结论, 该定理可用于分析 RM 和许多强化学习算法的收敛性。

Theorem 5.2 (Dvoretzkys convergence theorem). 考虑如下随机过程 (证明见附录C):

$$w_{k+1} = (1 - \alpha_k)w_k + \beta_k \eta_k, \quad (5.9)$$

其中 $\{\alpha_k\}_{k=1}^{\infty}, \{\beta_k\}_{k=1}^{\infty}, \{\eta_k\}_{k=1}^{\infty}$ 均为随机序列 (stochastic sequences), $\forall k, \alpha_k \geq 0, \beta_k \geq 0$, 那么 $w_k \xrightarrow{w.p.1} 0$, 若:

1. $\sum_{k=1}^{\infty} \alpha_k = \infty, \sum_{k=1}^{\infty} \alpha_k^2 < \infty; \sum_{k=1}^{\infty} \beta_k^2 < \infty$ uniformly w.p.1
2. $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0, \mathbb{E}[\eta_k^2 | \mathcal{H}_k] \leq C$ w.p.1, 其中 $\mathcal{H}_k = \{w_k, w_{k-1}, \dots, \eta_{k-1}, \dots, \alpha_{k-1}, \dots, \beta_{k-1}, \dots\}$.

Note 5.3. 关于 Dvoretzkys convergence theorem(DCT) 有如下几点说明:

1. DCT 中 $\{\alpha_k\}, \{\beta_k\}$ 依赖于 $\mathcal{H}_k$, 但在 RM 算法中 $\{\alpha_k\}$ 是确定性的, 不依赖于 $\mathcal{H}_k$.
2. DCT 的推广版本可用于分析后续的 Q-learning 和 TD learning 算法.

Theorem 5.3 (Extension of Dvoretzky's theorem). 设 $\mathcal{S}$ 为有限实数集. 对于随机过程

$$\Delta_{k+1}(s) = (1 - \alpha_k(s))\Delta_k(s) + \beta_k(s)\eta_k(s), \quad (5.10)$$

若对于每个 $s \in \mathcal{S}$, 满足以下条件, 则有 $\Delta_k(s) \rightarrow 0$ 几乎必然成立:

- (a) $\sum_k \alpha_k(s) = \infty, \sum_k \alpha_k^2(s) < \infty, \sum_k \beta_k^2(s) < \infty$, 并且 $\mathbb{E}[\beta_k(s) | \mathcal{H}_k] \leq \mathbb{E}[\alpha_k(s) | \mathcal{H}_k]$ 几乎必然一致成立;
- (b) $\|\mathbb{E}[\eta_k(s) | \mathcal{H}_k]\|_{\infty} \leq \gamma \|\Delta_k\|_{\infty}$, 其中 $\gamma \in (0, 1)$; $\text{var}[\eta_k(s) | \mathcal{H}_k] \leq C(1 + \|\Delta_k(s)\|_{\infty}^2)$, 其中 C 为常数.

$\mathcal{H}_k = \{\Delta_k, \Delta_{k-1}, \dots, \eta_{k-1}, \dots, \alpha_{k-1}, \dots, \beta_{k-1}, \dots\}$ 表示历史信息. 符号 $\|\cdot\|_{\infty}$ 表示最大范数(maximum norm).

Note 5.4. Mean estimation 问题可以归约为 RM 算法从而直接使用 **RM Theorem 5.1** 进行收敛性分析, 也可以使用 **Dvoretzky's Theorem 5.2** 分析, 详见附录C.

5.3 Stochastic Gradient Decent

Stochastic gradient descent – Algorithm

随机梯度下降 (Stochastic gradient descent, SGD) 算法是机器学习中的常用优化算法, 是梯度下降的随机化版本。

Problem statement. 考虑优化问题 $\min_w J(w) = \mathbb{E}[f(w, X)]$, 其中 w 为优化的目标变量、 X 为随机变量; w, X 可为标量也可以为向量, $f(\cdot)$ 为标量。

Gradient Decent (GD). 最基础的梯度下降法对解析式中的期望式求梯度, 再使用梯度进行更新:

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)], \quad (5.11)$$

其中 α_k 为步长, 控制下降的快慢. 实际使用中由于完整分布常未知, 会使用所有样本点进行梯度估计并更新:

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i), \quad w_{k+1} = w_k - \alpha_k \frac{1}{N} \sum_{i=1}^N \nabla_w f(w_k, x_i) \quad (5.12)$$

Batch Gradient Decent (BGD). 由于计算资源的限制和计算效率的要求, 一次性计算全量样本的梯度并更新往往不可行, 因此实际中会将完整数据集切分成小数据集 (大小为 B) 分批次进行 GD:

$$w_{k+1} = w_k - \alpha_k \frac{1}{B} \sum_{i=1}^B \nabla_w f(w_k, x_i) \quad (5.13)$$

Stochastic Gradient Decent(SGD). 为进一步降低计算量, 随机梯度下降每次仅使用一个随机样本计算梯度:

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k) \quad (5.14)$$

Stochastic gradient decent – Applying to mean estimation

Mean estimation 实际上是特殊的 SGD 算法，我们只需将其形式化为如下优化问题：

$$\min_w J(w) = \mathbb{E}[f(w, X)] \triangleq \mathbb{E} \left[\frac{1}{2} \|w - X\|^2 \right], \quad (5.15)$$

其中 $f(w, X) \triangleq \|w - X\|^2/2$ ，其梯度 $\nabla_w f(w, X) = w - X$ 。通过求解 $\nabla_w J(w) = 0$ 可以得到最优解 $w^* = \mathbb{E}[X]$ 。

GD for Eq. (5.15): $w_{k+1} = w_k - \alpha_k \nabla_w J(w_k) = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)] = w_k - \alpha_k \mathbb{E}[w_k - X]$ 。

SGD for Eq. (5.15): 使用单个样本代替期望， $w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k) = w_k - \alpha_k (w_k - x_k)$ 。可以看到这与 mean estimation 的算法(5.4)一样，因此 mean estimation 是特殊的 SGD。

Stochastic gradient decent – Convergence

对比 GD 与 SGD，二者不同就是 SGD 将梯度从无噪的对期望求梯度 ($\nabla_w \mathbb{E}[f(w_k, X)]$) 变成了有噪的对单样本点求梯度 ($\nabla_w f(w_k, x_k)$)，因此 $\nabla_w f(w_k, x_k)$ 就可以看作 $\nabla_w \mathbb{E}[f(w_k, X)] = \mathbb{E}[\nabla_w f(w, X)]$ 的有噪估计：

$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w, X)] + \underbrace{\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}. \quad (5.16)$$

Relative error analysis. 为衡量梯度计算发生改变带来的影响，定义如下梯度相对误差 (relative error)：

$$\delta_k \triangleq \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|}. \quad (5.17)$$

为简便起见，假设 $w, \nabla_w f(w_k, x_k)$ 均为标量且 $f(\cdot)$ 是严格凸的，根据拉格朗日中值定理有：

$$\delta_k = \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)] - \mathbb{E}[\nabla_w f(w^*, X)]|} = \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]|}, \quad (5.18)$$

其中 $\tilde{w}_k \in [w_k, w^*]$ 。由于已经假设函数 $f(\cdot)$ 是严格凸的，即 $\exists c > 0, \forall w, X, \nabla_w^2 f \geq c \geq 0$ ，有：

$$|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]| = |\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)]| |w_k - w^*| \geq c |w_k - w^*|. \quad (5.19)$$

代回式 (5.17) 中得：

$$\delta_k \leq \frac{\underbrace{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}_{\text{stochastic gradient}}}{\underbrace{c|w_k - w^*|}_{\text{true gradient, distance to the optimal solution}}}. \quad (5.20)$$

从上式可以看出 ① 当 $w_k - w^*$ 较大，即离最优解较远时，SGD 会表现得更像 GD，梯度下降更新的更准确；② 当 $w_k - w^*$ 较小，即离最优解较近时，相对误差上界增大，可能会存在更多的随机性，但是此时已经接近了最优解。

Theorem 5.4 (Convergence of SGD). 对于 SGD 算法(5.14)，定义满足 $\nabla_w \mathbb{E}[f(w, X)] = 0$ 的根为 w^* ，则 $w_k \xrightarrow{w.p.1} w^*$ 若满足以下条件：

1. $0 < c_1 \leq \nabla_w^2 f(w, X) \leq c_2$ (严格凸性)
2. $\sum_{k=1}^{\infty} a_k = \infty, \sum_{k=1}^{\infty} a_k^2 < \infty$ (与 RM 算法相同)
3. $\{x_k\}_{k=1}^{\infty}$ i.i.d. (常见要求)

首先优化问题 $\min_w J(w) = \mathbb{E}[f(w, X)]$ 在严格凸的条件下可以转化为如下求根问题：

$$J(w) = \mathbb{E}[f(w, X)] \Rightarrow g(w) \triangleq \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0. \quad (5.21)$$

令 $\tilde{g}(w, \eta) = \nabla_w f(w, x) = \underbrace{\mathbb{E}[\nabla_w f(w, X)]}_{g(w)} + \underbrace{\nabla_w f(w, x) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}$ ，那么解决 $g(w) = 0$ 的 RM 算法为：

$$w_{k+1} = w_k - a_k \tilde{g}(w_k, \eta_k) = w_k - a_k \nabla_w f(w_k, x_k). \quad (5.22)$$

此即 SGD，这样根据 Theorem 5.1 就可以得到上述结论。证明详见附录C。