

## 5 Lecture 5: Stochastic Approximation and Stochastic Gradient Descent

### 5.1 Robbins-Monro Algorithm (RM Algorithm)

#### Incremental update

许多算法中都涉及到收集样本并对某些值进行估计，常规的做法是使用非增量式计算 (**non-incremental**)，即等到  $N$  个样本采样完成后再进行下一步，但这往往会降低算法效率。一种替代方式是使用增量式 (**incremental**) 更新，即立即使用新的采样数据迭代更新目标量，这样虽然在算法初期损失了部分精度但无需等待、提升了算法效率。

**Example 5.1** (Mean Estimation). 在求经验期望时，非增量式计算会采样  $N$  个样本  $\{x_i\}_{i=1}^N$  并统一计算：

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N} \sum_{i=1}^N x_i \quad (5.1)$$

但若规定：

$$w_{k+1} = \frac{1}{k} \sum_{i=1}^k x_i, \quad k = 1, 2, \dots, N, \quad w_k = \frac{1}{k-1} \sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \dots, N. \quad (5.2)$$

那么就能得到如下 *incremental* 更新格式：

$$w_{k+1} = \frac{1}{k} \sum_{i=1}^k x_i = \frac{1}{k} \left( \sum_{i=1}^{k-1} x_i + x_k \right) = \frac{1}{k} ((k-1)w_k + x_k) = w_k - \frac{1}{k} (w_k - x_k) \quad (5.3)$$

一般地，上述 *mean estimation* 的 *incremental* 格式可以总结为：

$$w_{k+1} = w_k - \alpha_k (w_k - x_k), \quad (5.4)$$

其中  $\alpha_k > 0$ ，后续将说明当其满足一些条件时，仍然会保证收敛： $w_k \xrightarrow{k \rightarrow \infty} \mathbb{E}[X]$ 。

#### Robbins-Monro algorithm

Robbins-Monro (RM) 算法是随机近似算法 (Stochastic approximation, SA) 中的一种。SA 常用于方程求根问题和优化问题，相较于牛顿法、梯度下降等算法，SA 可以在函数表达式未知 (但可获得有噪输出) 的情况下使用迭代更新的方式求解问题。上述 *incremental* 格式的 *mean estimation* 和随机梯度下降 (SGD) 都是 RM 算法的特殊情况。

**Problem statement.** 考虑一个方程的求零点问题  $f(w) = 0$ ，其中  $f(w)$  为表达式未知的黑盒 (black box) (例如神经网络就可以抽象为  $f(w) = y$  的形式，但是  $g$  的形式是未知的)，我们只能获得有噪输出

$$\tilde{f}(w, \eta) = f(w) + \eta.$$

其中  $\eta$  为观测噪声。


**Note 5.1.** 实际上无约束凸优化问题和方程的求根问题都是  $f(w) = 0$  的形式：

$$\text{无约束凸优化问题: } f(w) = \nabla_w J(w) = 0 \quad \text{求根问题: } f(w) = c \Rightarrow h(w) \triangleq f(w) - c = 0$$

**Robbins-Monro (RM) algorithm.** RM 算法通过如下迭代方式逼近  $f(w) = 0$  的真实解：

$$w_{k+1} = w_k - a_k \tilde{f}(w_k, \eta_k), \quad k = 1, 2, 3, \dots, \quad (5.5)$$

其中  $w_k$  为对解的第  $k$  次估计。可以看出 RM 算法只依赖于输入和输出数据：① Input sequence:  $\{w_k\}$  ② Noisy output sequence:  $\{\tilde{f}(w_k, \eta_k)\}$ 。一个简单的求解  $f(x) = x^3 - 2 = 0$  的根的数值案例如下图所示，初始猜测  $x_0 = 0$ 。



## Robbins-Monro Algorithm – Convergence Analysis

**Theorem 5.1** (Robbins-Monro theorem). 对于 Robbins-Monro 算法, 若 ①  $\forall w, 0 < c_1 \leq \nabla_w f(w) \leq c_2$  (梯度假设) ②  $\sum_{k=1}^{\infty} a_k = \infty, \sum_{k=1}^{\infty} a_k^2 < \infty$  (系数假设) ③  $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0, \mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$  (误差假设), 其中  $\mathcal{H}_k = \{w_k, w_{k-1}, \dots\}$ . 设方程  $f(w) = 0$  的根为  $w^*$ , 满足  $f(w^*) = 0$ , 那么  $w_k$  以概率1收敛 (with probability 1, w.p.1) 至  $w^*$ .

**Note 5.2.** 对于上述三个条件, 有如下详细解读:

### 1. ① 梯度假设

- (a)  $\nabla_w f(w) > 0$ , 即原函数单调上升, 保证了方程  $f(w) = 0$  若有解则一定唯一. 这一条件一般可以满足, 例如当处理优化问题时,  $f(w)$  本身即梯度,  $\nabla f(w) > 0$  表示原函数是凸的, 即较常见的凸优化问题.
- (b)  $\nabla_w f(w) \leq c_2$  说明梯度有界, 不过不满足此条件算法有时也能够收敛.

### 2. ② 系数假设

- (a)  $\sum_{k=1}^{\infty} a_k^2 < \infty$  表明  $a_k \xrightarrow{k \rightarrow \infty} 0$ . 这可以保证  $w_{k+1} - w_k = -a_k \tilde{f}(w_k, \eta_k) \xrightarrow{k \rightarrow \infty} 0$ , 即收敛.
- (b)  $\sum_{k=1}^{\infty} a_k = \infty$  表明  $a_k \xrightarrow{k \rightarrow \infty} 0$  没有那么快. 将所有递推式  $w_{k+1} = w_k - a_k \tilde{f}(w_k, \eta_k)$  两端累和可以得到

$$w_1 - w_{\infty} = \sum_{k=1}^{\infty} a_k \tilde{f}(w_k, \eta_k)$$

若  $\sum_{k=1}^{\infty} a_k < \infty$ , 由于  $\tilde{f}$  有界, 那么  $|\sum_{k=1}^{\infty} a_k \tilde{f}(w_k, \eta_k)|$  有界, 这就要求初始猜测  $w_1$  不能距  $w^*$  过远, 反之若收敛至零较慢则可放宽对初始猜测的要求.

- (c) 取  $a_k = \frac{1}{k}$  是可以满足要求的, 因为  $\sum_{k=1}^n \frac{1}{k} \xrightarrow{n \rightarrow \infty} \infty, \sum_{k=1}^{\infty} \frac{1}{k^2} < \infty$ , 原因在于:

$$\lim_{n \rightarrow \infty} \left( \sum_{k=1}^n \frac{1}{k} - \ln n \right) = \kappa, \ln n \xrightarrow{n \rightarrow \infty} \infty \Rightarrow \sum_{k=1}^n \frac{1}{k} \xrightarrow{n \rightarrow \infty} \infty, \sum_{k=1}^{\infty} \frac{1}{k^2} = \frac{\pi^2}{6} < \infty \text{ (Basel problem)}. \quad (5.6)$$

其中  $\kappa \approx 0.577$  为 Euler-Mascheroni 常数<sup>a</sup>.

- (d) 常见的做法并非令系数为  $\frac{1}{k}$ , 因为当  $k$  较大时, 后面的数据在算法中起到的作用被无限缩小, 这并不是我们想要的, 因此常见的做法是开始时赋予较小的值再慢慢减小但不至于趋于 0
3. ③ – 测量误差假设. 这里并不要求  $\eta$  满足高斯性, 常见的做法是取  $\{\eta_k\}$  来自一个 i.i.d. 的随机序列, 满足  $\mathbb{E}[\eta_k | \mathcal{H}_k] = \mathbb{E}[\eta_k] = 0, \mathbb{E}[\eta_k^2 | \mathcal{H}_k] = \mathbb{E}[\eta_k^2] < \infty$ .

<sup>a</sup>欧拉-马斯刻若尼常数是一个数学常数, 定义为调和级数与自然对数的差值

## Robbins-Monro algorithm – Applying to mean estimation

定义  $f(w) \triangleq w - \mathbb{E}[X]$ , 我们需要求出  $f(w) = 0$  的解  $w^*$ , 可以定义有噪观测为  $\tilde{f}(w, x) \triangleq w - x$ , 那么可以得到:

$$\tilde{f}(w, \eta) = (w - \mathbb{E}[X]) + (\mathbb{E}[X] - x) \triangleq f(w) + \eta \quad (5.7)$$

其中  $\eta \triangleq \mathbb{E}[X] - x$ ,  $x$  是对  $X$  的采样. 代入 RM 算法 (5.5) 中就可得到:

$$w_{k+1} = w_k - \alpha_k \tilde{f}(w_k, \eta_k) = w_k - \alpha_k (w_k - x_k) \quad (5.8)$$

再套用 Theorem 5.1 即可得到相应的收敛性结论, 并且此收敛性不要求  $X$  服从高斯分布或其他特定分布族, 但仍需满足相应的矩条件和采样条件. 其收敛性分析也可以直接使用 Dvoretzky's convergence theorem, 详细证明见附录C.

## 5.2 Dvoretzky's Convergence Theorem

### Dvoretzkys convergence theorem

Dvoretzkys convergence theorem 是 SA 领域的经典结论, 该定理可用于分析 RM 和许多强化学习算法的收敛性。

**Theorem 5.2** (Dvoretzkys convergence theorem). 考虑如下随机过程 (证明见附录C):

$$w_{k+1} = (1 - \alpha_k)w_k + \beta_k \eta_k, \quad (5.9)$$

其中  $\{\alpha_k\}_{k=1}^{\infty}, \{\beta_k\}_{k=1}^{\infty}, \{\eta_k\}_{k=1}^{\infty}$  均为随机序列 (stochastic sequences),  $\forall k, \alpha_k \geq 0, \beta_k \geq 0$ , 那么  $w_k \xrightarrow{w.p.1} 0$ , 若:

1.  $\sum_{k=1}^{\infty} \alpha_k = \infty, \sum_{k=1}^{\infty} \alpha_k^2 < \infty; \sum_{k=1}^{\infty} \beta_k^2 < \infty$  uniformly w.p.1
2.  $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0, \mathbb{E}[\eta_k^2 | \mathcal{H}_k] \leq C$  w.p.1, 其中  $\mathcal{H}_k = \{w_k, w_{k-1}, \dots, \eta_{k-1}, \dots, \alpha_{k-1}, \dots, \beta_{k-1}, \dots\}$ .

**Note 5.3.** 关于 Dvoretzkys convergence theorem(DCT) 有如下几点说明:

1. DCT 中  $\{\alpha_k\}, \{\beta_k\}$  依赖于  $\mathcal{H}_k$ , 但在 RM 算法中  $\{\alpha_k\}$  是确定性的, 不依赖于  $\mathcal{H}_k$ .
2. DCT 的推广版本可用于分析后续的 Q-learning 和 TD learning 算法.

**Theorem 5.3** (Extension of Dvoretzky's theorem). 设  $\mathcal{S}$  为有限实数集. 对于随机过程

$$\Delta_{k+1}(s) = (1 - \alpha_k(s))\Delta_k(s) + \beta_k(s)\eta_k(s), \quad (5.10)$$

若对于每个  $s \in \mathcal{S}$ , 满足以下条件, 则有  $\Delta_k(s) \rightarrow 0$  几乎必然成立:

- (a)  $\sum_k \alpha_k(s) = \infty, \sum_k \alpha_k^2(s) < \infty, \sum_k \beta_k^2(s) < \infty$ , 并且  $\mathbb{E}[\beta_k(s) | \mathcal{H}_k] \leq \mathbb{E}[\alpha_k(s) | \mathcal{H}_k]$  几乎必然一致成立;
- (b)  $\|\mathbb{E}[\eta_k(s) | \mathcal{H}_k]\|_{\infty} \leq \gamma \|\Delta_k\|_{\infty}$ , 其中  $\gamma \in (0, 1)$ ;  $\text{var}[\eta_k(s) | \mathcal{H}_k] \leq C(1 + \|\Delta_k(s)\|_{\infty}^2)$ , 其中  $C$  为常数.

$\mathcal{H}_k = \{\Delta_k, \Delta_{k-1}, \dots, \eta_{k-1}, \dots, \alpha_{k-1}, \dots, \beta_{k-1}, \dots\}$  表示历史信息. 符号  $\|\cdot\|_{\infty}$  表示最大范数(maximum norm).

**Note 5.4.** Mean estimation 问题可以归约为 RM 算法从而直接使用 **RM Theorem 5.1** 进行收敛性分析, 也可以使用 **Dvoretzky's Theorem 5.2** 分析, 详见附录C.

## 5.3 Stochastic Gradient Decent

### Stochastic gradient descent – Algorithm

随机梯度下降 (Stochastic gradient descent, SGD) 算法是机器学习中的常用优化算法, 是梯度下降的随机化版本。

**Problem statement.** 考虑优化问题  $\min_w J(w) = \mathbb{E}[f(w, X)]$ , 其中  $w$  为优化的目标变量、 $X$  为随机变量;  $w, X$  可为标量也可以为向量,  $f(\cdot)$  为标量。

**Gradient Decent (GD).** 最基础的梯度下降法对解析式中的期望式求梯度, 再使用梯度进行更新:

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)], \quad (5.11)$$

其中  $\alpha_k$  为步长, 控制下降的快慢. 实际使用中由于完整分布常未知, 会使用所有样本点进行梯度估计并更新:

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i), \quad w_{k+1} = w_k - \alpha_k \frac{1}{N} \sum_{i=1}^N \nabla_w f(w_k, x_i) \quad (5.12)$$

**Mini-Batch Gradient Decent (BGD).** 由于计算资源的限制和计算效率的要求, 一次性计算全量样本的梯度并更新往往不可行, 因此实际中会将完整数据集切分成小数据集 (大小为  $B$ ) 分批次进行 GD:

$$w_{k+1} = w_k - \alpha_k \frac{1}{B} \sum_{i=1}^B \nabla_w f(w_k, x_i) \quad (5.13)$$

**Stochastic Gradient Decent (SGD).** 为进一步降低计算量, 随机梯度下降每次仅使用一个随机样本计算梯度:

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k) \quad (5.14)$$

### Stochastic gradient decent – Applying to mean estimation

Mean estimation 实际上是特殊的 SGD 算法，我们只需将其形式化为如下优化问题：

$$\min_w J(w) = \mathbb{E}[f(w, X)] \triangleq \mathbb{E} \left[ \frac{1}{2} \|w - X\|^2 \right], \quad (5.15)$$

其中  $f(w, X) \triangleq \|w - X\|^2/2$ ，其梯度  $\nabla_w f(w, X) = w - X$ 。通过求解  $\nabla_w J(w) = 0$  可以得到最优解  $w^* = \mathbb{E}[X]$ 。

**GD for Eq. (5.15):**  $w_{k+1} = w_k - \alpha_k \nabla_w J(w_k) = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)] = w_k - \alpha_k \mathbb{E}[w_k - X]$ 。

**SGD for Eq. (5.15):** 使用单个样本代替期望， $w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k) = w_k - \alpha_k (w_k - x_k)$ 。可以看到这与 mean estimation 的算法(5.4)一样，因此 mean estimation 是特殊的 SGD。

### Stochastic gradient decent – Convergence

对比 GD 与 SGD，二者不同就是 SGD 将梯度从无噪的对期望求梯度 ( $\nabla_w \mathbb{E}[f(w_k, X)]$ ) 变成了有噪的对单样本点求梯度 ( $\nabla_w f(w_k, x_k)$ )，因此  $\nabla_w f(w_k, x_k)$  就可以看作  $\nabla_w \mathbb{E}[f(w_k, X)] = \mathbb{E}[\nabla_w f(w, X)]$  的有噪估计：

$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w, X)] + \underbrace{\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}. \quad (5.16)$$

**Relative error analysis.** 为衡量梯度计算发生改变带来的影响，定义如下梯度相对误差 (relative error)：

$$\delta_k \triangleq \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|}. \quad (5.17)$$

为简便起见，假设  $w, \nabla_w f(w_k, x_k)$  均为标量且  $f(\cdot)$  是严格凸的，根据拉格朗日中值定理有：

$$\delta_k = \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)] - \mathbb{E}[\nabla_w f(w^*, X)]|} = \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]|}, \quad (5.18)$$

其中  $\tilde{w}_k \in [w_k, w^*]$ 。由于已经假设函数  $f(\cdot)$  是严格凸的，即  $\exists c > 0, \forall w, X, \nabla_w^2 f \geq c \geq 0$ ，有：

$$|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]| = |\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)]| |w_k - w^*| \geq c |w_k - w^*|. \quad (5.19)$$

代回式 (5.17) 中得：

$$\delta_k \leq \frac{\underbrace{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}_{\text{stochastic gradient}}}{\underbrace{c|w_k - w^*|}_{\text{true gradient, distance to the optimal solution}}}. \quad (5.20)$$

从上式可以看出 ① 当  $w_k - w^*$  较大，即离最优解较远时，SGD 会表现得更像 GD，梯度下降更新的更准确；② 当  $w_k - w^*$  较小，即离最优解较近时，相对误差上界增大，可能会存在更多的随机性，但是此时已经接近了最优解。

**Theorem 5.4 (Convergence of SGD).** 对于 SGD 算法(5.14)，定义满足  $\nabla_w \mathbb{E}[f(w, X)] = 0$  的根为  $w^*$ ，则  $w_k \xrightarrow{w.p.1} w^*$  若满足以下条件：

1.  $0 < c_1 \leq \nabla_w^2 f(w, X) \leq c_2$  (严格凸性)
2.  $\sum_{k=1}^{\infty} a_k = \infty, \sum_{k=1}^{\infty} a_k^2 < \infty$  (与 RM 算法相同)
3.  $\{x_k\}_{k=1}^{\infty}$  i.i.d. (常见要求)

首先优化问题  $\min_w J(w) = \mathbb{E}[f(w, X)]$  在严格凸的条件下可以转化为如下求根问题：

$$J(w) = \mathbb{E}[f(w, X)] \Rightarrow g(w) \triangleq \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0. \quad (5.21)$$

令  $\tilde{g}(w, \eta) = \nabla_w f(w, x) = \underbrace{\mathbb{E}[\nabla_w f(w, X)]}_{g(w)} + \underbrace{\nabla_w f(w, x) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}$ ，那么解决  $g(w) = 0$  的 RM 算法为：

$$w_{k+1} = w_k - a_k \tilde{g}(w_k, \eta_k) = w_k - a_k \nabla_w f(w_k, x_k). \quad (5.22)$$

此即 SGD，这样根据 Theorem 5.1 就可以得到上述结论。证明详见附录C。